

UTH Scientific Data Mining: Swagger API & Functional Specification

Hệ thống Khai phá Dữ liệu Khoa học Thời gian thực & RAG Phục vụ AI/DS (FastAPI :8000/docs)

Quy mô Corpus: 10,000 - 13,000 bài báo khoa học (arXiv, OpenAlex)

Lưu trữ Hồ Dữ liệu: Cloudflare R2 (Bronze), Parquet (Silver), LanceDB (Gold)

Thời gian thực thi Mining: ~64.56 giây (Toàn bộ 4 Pillars)

Công thức Toán bóc tách: 2,220,938 biểu thức KaTeX

Tổng từ vựng học thuật: 47,782,707 từ

Cộng đồng trích dẫn: 35,117 tác giả / 130,082 liên kết

PHẦN 1: TỔNG QUAN KHÁM PHÁ DỮ LIỆU & KIỂM TRA HỆ THỐNG (EDA & TELEMETRY)

GET /api/mining/eda

Mục đích: Trả về toàn bộ số liệu Khám phá Dữ liệu (Exploratory Data Analysis - EDA), cấu trúc bài báo, phân bố danh mục, tác giả tiêu biểu và mật độ công thức toán học.

Khối Dữ Liệu (Field)	Kiểu dữ liệu	Mô tả chi tiết & Chức năng cụ thể
dataset_overview	Object (EdaOverview)	Tổng quan corpus: total_papers (10,000), enriched_html_papers (9,015 - tỷ lệ 90.15%), total_math_formulas (2.22M), total_words (47.78M), avg_math_per_paper (222 công thức/bài), khoảng thời gian xuất bản (2005 - 2024).
category_distribution	Array[CategoryDi	Phân bố chuyên ngành AI/DS: cs.AI, cs.LG, cs.CV,

Khối Dữ Liệu (Field)	Kiểu dữ liệu	Mô tả chi tiết & Chức năng cụ thể
	<code>stItem]</code>	cs.CL, stat.ML kèm số lượng bài, tỷ lệ phần trăm, tổng số công thức toán và độ dài bài viết trung bình theo từng ngành.
temporal_distribution	<code>Array[TemporalDistItem]</code>	Phân bố số lượng bài báo theo trục thời gian (theo quý/năm) để quan sát sự bùng nổ của các nghiên cứu AI theo từng giai đoạn.
top_authors	<code>Array[TopAuthorItem]</code>	Bảng xếp hạng các tác giả có số lượng công trình nhiều nhất trong tập dữ liệu.
category_cooccurrence	<code>Array[CategoryCooccur]</code>	Ma trận đồng xuất hiện giữa các chuyên ngành (vd: cs.AI đi kèm cs.CV hoặc cs.LG), hỗ trợ vẽ biểu đồ Heatmap trên Frontend.
math_and_content_stats	<code>object</code>	Thống kê phân vị mật độ công thức toán: min, 25%, median (50%), 75%, max và độ lệch chuẩn.

GET /api/mining/telemetry/stream

Mục đích: Kênh truyền dữ liệu thời gian thực Server-Sent Events (SSE) liên tục phát nhịp tim (heartbeat) CPU, RAM, trạng thái I/O của hồ dữ liệu về giao diện Dashboard.

Thuộc tính SSE Pulse	Kiểu dữ liệu	Mô tả chi tiết & Chức năng cụ thể
event: telemetry	<code>JSON String</code> <code>(1 pulse/sec)</code>	Chứa <code>cpu_usage_pct</code> , <code>memory_mb</code> , <code>active_threads</code> , <code>lakehouse_papers_count</code> , <code>sse_uptime_seconds</code> phục vụ vẽ Live Telemetry Feed tại khay công cụ đáy (Drawer).

PHẦN 2: BỐN TRỤ CỘT KHAI PHÁ DỮ LIỆU KHOA HỌC (THE 4 MINING PILLARS)

GET /api/mining/pillars/association-rules

PILLAR 1 Khai phá Tập phổ biến & Luật kết hợp (FP-Growth Algorithm)

Thuật toán FP-Growth quét 11,404 giao dịch bài báo (87.7% corpus) để tìm ra các cặp công nghệ/danh mục luôn xuất hiện cùng nhau một cách có ý nghĩa thống kê cao.

Trường trả về	Kiểu dữ liệu	Ý nghĩa chỉ số thống kê & Ứng dụng
summary	Object	Chứa total_transactions (11.4k), min_support (0.015), min_confidence (0.25), total_rules_found (22 luật chất lượng cao đã khử đối xứng).
frequent_itemsets	Array[Item set]	Danh sách các tập mục phổ biến (1-itemset, 2-itemset, 3-itemset) vượt qua ngưỡng Support tối thiểu.
rules[].antecedents	Array[String]	Về điều kiện (X), ví dụ: ['tag:reinforcement-learning'] hoặc ['cat:cs.CL', 'cat:cs.AI'].
rules[].consequents	Array[String]	Về hệ quả suy ra (Y), ví dụ: ['tag:autonomous-agents'] hoặc ['tag:large-language-models'].
rules[].support	Float (0.0 - 1.0)	Tần suất xuất hiện đồng thời cả X và Y trên toàn bộ tập dữ liệu ($P(X \cap Y)$).
rules[].confidence	Float (0.0 - 1.0)	Độ tin cậy: Xác suất bài báo có Y khi đã biết chắc chắn có X ($P(Y X)$).
rules[].lift	Float (> 1.0)	Độ nâng (Lift): Mức độ tương quan thực sự. Lift > 1 chứng minh sự kết hợp xảy ra vượt trội ngẫu nhiên (Vd: Lift đạt 6.33x đến 27.07x).
rules[].leverage & conviction	Float	Hai chỉ số hiệu chỉnh đo lường sự chênh lệch xác suất độc lập và độ kháng lỗi suy luận.

GET /api/mining/pillars/clusters

PILLAR 2 Phân cụm Chủ đề Ngữ nghĩa & Phân tích Mật độ (Semantic Topic Clustering)

Sử dụng MiniBatch K-Means (K=6) kết hợp mật độ DBSCAN trên không gian vector nhúng L2-normalized. Chiếu giảm chiều PCA 2D Centered để vẽ biểu đồ tọa độ không bị trôi tâm.

Trường trả về	Kiểu dữ liệu	Mô tả chi tiết & Chức năng cụ thể
validity_metrics	Object	Các chỉ số kiểm định độ tin cậy phân cụm toán học: Silhouette Score (+0.0216), Davies-Bouldin Index (đo độ tách biệt giữa các cụm), Calinski-Harabasz Score.
cluster_profiles	Array[ClusterProfile]	Hồ sơ 6 cụm đề tài: cluster_id, size, percentage, danh mục áp

Trường trả về	Kiểu dữ liệu	Mô tả chi tiết & Chức năng cụ thể
		đảo (dominant_categories), và 5 tiêu đề bài báo đại diện nhất cụm.
scatter_2d	Array[ScatterPoint]	Tập hợp tọa độ (x, y) sau khi chiếu PCA 2D cho từng bài báo, kèm cluster_id, category, title, paper_id để vẽ biểu đồ Manifold trực quan tương tác.
GET /api/mining/pillars/graph		

PILLAR 3 Khai phá Đồ thị Đồng tác giả & Mạng lưới Trích dẫn (Citation & Graph Mining)

Mô hình hóa mạng lưới học thuật gồm 35,117 tác giả và 130,082 liên kết hợp tác. Ứng dụng Directed PageRank tìm các tác giả/bài báo trụ cột và thuật toán Louvain phát hiện 92 cộng đồng nghiên cứu.

Trường trả về	Kiểu dữ liệu	Mô tả chi tiết & Chức năng cụ thể
network_summary	Object	Chỉ số cấu trúc đồ thị: total_nodes, total_edges, graph_density, average_degree, số lượng cộng đồng phát hiện (92 modularity communities).
top_influencers	Array[Influencer]	Bảng xếp hạng Top học giả dẫn đầu dựa trên điểm Directed PageRank và Degree Centrality (số liên kết cộng tác).
communities	Array[Community]	Danh sách các nhóm nghiên cứu (Louvain clusters), quy mô thành viên và các chủ đề cốt lõi mà cộng đồng tập trung.
graph_export	Object (Nodes & Links)	Định dạng JSON D3.js tương thích cao gồm nodes[] (id, label, pagerank, community) và links[] (source, target, weight) để dựng mạng lưới trực quan tương tác.

GET /api/mining/pillars/trends

PILLAR 4 Đo lường Vận tốc Xu hướng & Phát hiện Dị biệt Đột phá (Trends & Anomalies)

Ứng dụng thuật toán Isolation Forest đa chiều để bóc tách 30 công trình có cấu trúc dị biệt cực đoan (độ dài, mật độ toán, số lượng tác giả). Đo lường Share-Normalized Growth Velocity để phân loại động lượng ngành.

Trường trả về	Kiểu dữ liệu	Mô tả chi tiết & Chức năng cụ thể
trend_velocity	Array[TrendVelocityItem]	Vận tốc tăng trưởng từng ngành: recent_quarter_papers, previous_quarter_papers, growth_rate_pct, all_time_papers và nhấn động lượng momentum (SURGING: tăng vọt, STABLE:

Trường trả về	Kiểu dữ liệu	Mô tả chi tiết & Chức năng cụ thể
		ổn định, DECLINING: suy giảm).
anomalies	<code>Array[AnomalyItem]</code>	Top 30 bài báo dị biệt: paper_id, title, anomaly_score (điểm cô lập Isolation Forest), math_count, word_count, author_count, kèm lý do định tính (outlier_reasons).

PHẦN 3: ĐIỀU KHIỂN & THEO DÕI VẬN HÀNH (ORCHESTRATION & CONTROL)

GET /api/mining/manifest

Mục đích: Trích xuất bảng kê khai thực thi (Execution Manifest) của lần chạy gần nhất: mốc thời gian, nguồn dữ liệu Parquet/LanceDB, và thời gian thực thi (elapsed_seconds) của từng module thuật toán.

POST /api/mining/trigger

Mục đích: Lệnh gọi bất đồng bộ (Background Task) kích hoạt lại toàn bộ Master Mining Engine (`MiningEngine.run_all(upload_to_r2=True)`) trên máy chủ để tính toán lại 4 trụ cột khi có dữ liệu mới. Trả về status: "QUEUED".