

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI TP.HCM
VIỆN CÔNG NGHỆ THÔNG TIN VÀ ĐIỆN, ĐIỆN TỬ

DATA MINING

CHƯƠNG I: TỔNG QUAN VỀ DATA MINING

TS. Trần Thế Vinh



Dữ liệu là gì?

Dữ liệu là tập hợp các sự kiện, thông tin và số liệu thống kê, nó có thể ở nhiều dạng khác nhau như số, văn bản, hình ảnh, âm thanh hoặc bất kỳ định dạng nào khác.



Dữ liệu là gì?

DỮ LIỆU THÔ (RAW DATA)





- Dữ liệu thô (Raw Data): Là dữ liệu nguyên bản, “chưa qua xử lý” hay biến đổi, có thể ở nhiều định dạng khác nhau như văn bản (text), hình ảnh (image), âm thanh (voice), video, hoặc dữ liệu cảm biến. trước khi được các nhà nghiên cứu “làm sạch” và hiệu chỉnh nó.
- Quá trình xử lý dữ liệu thường diễn ra theo từng giai đoạn và do đó “dữ liệu đã xử lý” từ một giai đoạn trước cũng có thể được coi là “dữ liệu thô” của các giai đoạn tiếp theo.
- Dữ liệu hiện trường(Field Data): Là dữ liệu được thu thập trực tiếp từ môi trường thực tế (on-site), trong điều kiện tự nhiên, không kiểm soát.
- Dữ liệu thử nghiệm(Experimental Data): Là dữ liệu được tạo ra từ các thiết kế thử nghiệm hoặc quan sát có kiểm soát, thường được thực hiện trong môi trường khoa học như phòng thí nghiệm, mô phỏng hoặc hệ thống sandbox.

Dữ liệu có thể được tạo ra bởi: con người, máy móc, sự kết hợp giữa người và máy

Hệ sinh thái dữ liệu

Dữ liệu ngày nay không chỉ nằm trong Excel hay SQL



Dữ liệu đến từ:

- Ứng dụng web/mobile
- IoT, thiết bị cảm biến, camera,...
- CRM, ERP, E-commerce, Social Network



Do đó chúng ta cần có hệ sinh thái gồm nhiều công cụ để thu thập, xử lý, lưu trữ và khai thác những dữ liệu đó.

Phân loại dữ liệu

Dữ liệu có cấu trúc

- Loại dữ liệu này được tổ chức theo định dạng cụ thể, giúp dễ dàng tìm kiếm, phân tích và xử lý. (Excel, SQL Table)


Dữ liệu phi cấu trúc

- Loại dữ liệu này không tuân theo một cấu trúc hoặc định dạng cụ thể. Nó có thể bao gồm một số dạng văn bản, hình ảnh, video, audio và dữ liệu khác.
- Không dễ dàng được sắp xếp hoặc phân tích nếu không có quá trình xử lý bổ sung

Dữ liệu bán cấu trúc

- Loại dữ liệu có một số cấu trúc nhất định nhưng không đầy đủ, ví dụ: JSON, XML

Thông tin là gì?



- Thông tin là dữ liệu đã được xử lý, sắp xếp hoặc cấu trúc theo cách khiến nó có ý nghĩa, có giá trị và hữu ích.
 - Đó là dữ liệu đã được cung cấp ngữ cảnh, sự liên quan và mục đích.
 - Cung cấp các kiến thức (knowledge), sự hiểu biết và hiểu biết sâu sắc có thể được sử dụng để ra quyết định, giải quyết vấn đề, giao tiếp và nhiều mục đích khác.
 - Ví dụ:
 - Từ điểm số thô → Trung bình môn → Xếp loại
- Dữ liệu thô (raw): 7.0, 6.5, 7.5. → Thông tin (có ý nghĩa): Điểm trung bình: 7 – loại khá.

Dữ liệu + Xử lý + Ngữ cảnh = Thông tin.

Tại sao dữ liệu lại quan trọng



Dữ liệu là nền tảng cho:

- Kinh doanh thông minh (BI)
- Máy học (ML)
- Ra quyết định (Decision Support)
- Cá nhân hoá (Personalization)

Nếu bạn là chủ một quán cà phê – bạn sẽ dùng dữ liệu để cải thiện điều gì?

- ✓ Doanh thu theo giờ?
- ✓ Sản phẩm bán chạy?
- ✓ Feedback khách hàng?

Dữ liệu → Tri thức



Ví dụ: Quán nhậu và việc bán **“Bia kèm lạc”**

- Dữ liệu thô: Nhật ký bán hàng: món ăn, thời gian, số lượng, hoá đơn.
- Xử lý dữ liệu: Làm sạch dữ liệu: nhóm món theo loại, tổng hợp theo thời gian.
- Thông tin: 75% khách gọi bia + lạc
- Phân tích mẫu: Nếu gọi bia => 80% gọi lạc
- Tri thức: Mối quan hệ chặt chẽ giữa bia và lạc
- Ra quyết định: Đặt bia và lạc gần nhau trong menu


“Vậy nếu dữ liệu có thể trở thành kiến thức quý giá, chúng ta cần một quy trình để làm việc đó. Và đó là nơi **khai phá dữ liệu (Data Mining)** xuất hiện...”

Khai thác dữ liệu là gì?

- Khai thác dữ liệu là quá trình khám phá các mẫu và mối quan hệ trong các tập dữ liệu lớn bằng các kỹ thuật như máy học, phân tích thống kê, trí tuệ nhân tạo, hệ thống quản lý cơ sở dữ liệu.
- Mục đích:
 - Trích xuất thông tin hữu ích từ các tập dữ liệu lớn
 - Sử dụng để đưa ra dự đoán hoặc thông báo cho việc ra quyết định.



Vì sao chúng ta cần phải khai phá dữ liệu?



Ví dụ:


- Shopee: Gợi ý sản phẩm dựa trên hành vi khách hàng
- Ngân hàng: Phát hiện giao dịch gian lận
- Y tế: Dự đoán nguy cơ bệnh từ lịch sử hồ sơ bệnh án

Do đó, Data Mining xuất phát từ đâu, và nó dựa trên những nền tảng nào?????

Nguồn gốc và sự phát triển của Data Mining



Statistics $\cap$ Database $\cap$ ML = Data Mining



Để Data Mining có thể vận hành, ta cần hiểu quy trình tổng thể của khai phá tri thức từ dữ liệu. Đây chính là nơi **KDD** và **CRISP-DM** ra đời...

KDD – Quy trình học thuật khai phá dữ liệu

1. Lựa chọn dữ liệu (Selection)

- Xác định mục tiêu phân tích và lựa chọn dữ liệu liên quan từ nhiều nguồn
- Đảm bảo dữ liệu phản ánh đúng bài toán

2. Tiền xử lý dữ liệu (Preprocessing)

- Làm sạch dữ liệu: xử lý giá trị thiếu, nhiễu, ngoại lệ
- Chuẩn hóa định dạng để đảm bảo nhất quán

3. Chuyển đổi dữ liệu (Transformation)

- Tích hợp, tổng hợp và chuyển đổi dữ liệu sang dạng phù hợp
- Trích xuất đặc trưng, chuẩn hóa giá trị thuộc tính

4. Khai phá dữ liệu (Data Mining)


- Áp dụng các kỹ thuật như:
 - Phân lớp (Classification)
 - Phân cụm (Clustering)
 - Khai phá luật kết hợp (Association Rules)
- Tìm ra mẫu, xu hướng, mối quan hệ ẩn

5. Đánh giá & Diễn giải (Evaluation)

- Đánh giá độ chính xác, mức độ hữu ích của các mô hình
- Diễn giải kết quả phù hợp với bối cảnh nghiệp vụ

6. Trình bày tri thức (Knowledge Presentation)


- Truyền đạt kết quả bằng biểu đồ, bảng, báo cáo hoặc dashboard
- Hỗ trợ ra quyết định, triển khai giải pháp



CRISP-DM– Quy trình chuẩn công nghiệp

CRISP-DM (Cross Industry Standard Process for Data Mining) là một mô hình quy trình chuẩn ngành dùng để thực hiện các dự án khai phá dữ liệu (**data mining**) và phân tích dữ liệu (**data analytics**).

Mô hình này được giới thiệu lần đầu vào năm 1999, được phát triển bởi tập đoàn IBM, Daimler-Benz và NCR, và đến nay vẫn là một trong những khung làm việc phổ biến nhất trong khoa học dữ liệu.



*Điều quan trọng: **Không nên nhầm lẫn kỹ thuật là quy trình.** Quy trình là tư duy phân tích, kỹ thuật là công cụ hỗ trợ triển khai.*

CRISP-DM– Quy trình chuẩn công nghiệp

1. Hiểu biết nghiệp vụ (Business Understanding)

Mục tiêu: Hiểu rõ vấn đề kinh doanh cần giải quyết.

- Xác định mục tiêu cuối cùng của dự án từ góc nhìn nghiệp vụ.
- Định nghĩa câu hỏi cốt lõi mà mô hình cần trả lời (VD: dự đoán nhu cầu, phân loại khách hàng, phát hiện rủi ro).
- Thiết lập tiêu chí đánh giá thành công của dự án (KPIs, ROI,...).


Ví dụ: "Làm sao để giảm tỷ lệ khách hàng rời bỏ dịch vụ trong 3 tháng tới?"

2. Hiểu biết dữ liệu (Data Understanding)

Mục tiêu: Thu thập và khám phá dữ liệu ban đầu để đánh giá chất lượng và sự phù hợp.

- Xác định nguồn dữ liệu (text, image, voice, video, database,...).
- Khám phá sơ bộ dữ liệu: phân phối, thiếu dữ liệu, dữ liệu bất thường,...
- Xác nhận tính liên quan giữa dữ liệu và mục tiêu nghiệp vụ.

Ví dụ: Tập khách hàng có bao nhiêu trường, có trường nào bị thiếu hoặc lỗi không? Có trùng không?



CRISP-DM– Quy trình chuẩn công nghiệp

3. Chuẩn bị dữ liệu (Data Preparation)

Mục tiêu: Làm sạch và xử lý dữ liệu để đưa vào mô hình.

- **Trích xuất (Extract):** Thu thập dữ liệu từ các hệ thống khác nhau (CSDL, API, file, stream,...).
- **Chuyển đổi (Transform):** Làm sạch (xử lý thiếu, trùng, sai kiểu), biến đổi (scale, encode, feature engineering).
- **Nạp (Load):** Đưa dữ liệu đã xử lý vào hệ thống lưu trữ phù hợp (data warehouse, data lake,...).


Lưu ý: Đây là bước tốn nhiều thời gian nhất – chiếm 60-80% công sức của toàn bộ dự án.

4. Xây dựng mô hình (Modeling)

Mục tiêu: Áp dụng các kỹ thuật học máy để xây dựng mô hình dự đoán hoặc phân tích.

- Chọn kỹ thuật phù hợp: phân loại, hồi quy, phân cụm, phát hiện bất thường,...
- Chia dữ liệu thành tập huấn luyện / kiểm thử.
- Tinh chỉnh siêu tham số (hyperparameters) và kiểm tra các mô hình khác nhau.
- Đánh giá mô hình bằng các chỉ số như Accuracy, F1-score, RMSE, AUC,...

Lưu ý: Có thể thử nhiều mô hình song song để chọn ra mô hình tốt nhất.



CRISP-DM– Quy trình chuẩn công nghiệp

5. Đánh giá (Evaluation)

Mục tiêu: Xác nhận rằng mô hình được xây dựng thực sự giải quyết được mục tiêu nghiệp vụ.

- So sánh kết quả mô hình với mục tiêu ban đầu.
- Phân tích hiệu quả trong từng nhóm dữ liệu (nhóm khách hàng, vùng địa lý, thời gian...).
- Kiểm tra các rủi ro tiềm ẩn (overfitting, bias, interpretability).
- Quyết định có nên triển khai mô hình hay cần quay lại bước chuẩn bị / mô hình hóa.


Câu hỏi then chốt: "Mô hình này có đủ tốt để đưa vào thực tế không?"

6. Triển khai (Deployment)

Mục tiêu: Đưa mô hình và kết quả phân tích vào hoạt động thực tế.

- Hình thức triển khai có thể là:
 - Báo cáo trực quan (dashboard, slide)
 - API dự đoán tích hợp vào hệ thống
 - Chiến dịch hành động (marketing, vận hành, quản trị rủi ro)
- Lên kế hoạch bảo trì, theo dõi mô hình (model monitoring).
- Thiết lập pipeline tự động nếu cần cập nhật mô hình định kỳ.


Lưu ý: Triển khai không phải là kết thúc – cần theo dõi hiệu quả dài hạn và tái huấn luyện nếu cần.



Data Pipeline

- **Thu thập(Collect):** Dữ liệu được thu thập từ kho dữ liệu, luồng dữ liệu và ứng dụng, có nguồn gốc từ các thiết bị, ứng dụng hoặc hệ thống kinh doanh
- **Nạp(Ingest):** Trong quá trình thu thập, dữ liệu được tải vào hệ thống và được sắp xếp trong hàng đợi sự kiện (event queue)
- **Lưu trữ(Store):** Sau khi thu thập, dữ liệu được sắp xếp sẽ được lưu trữ trong các kho dữ liệu (data warehouse), hồ dữ liệu (data lake), trung tâm dữ liệu, cùng với nhiều hệ thống khác như CSDL, đảm bảo lưu trữ sau khi thu thập.
- **Tính toán(Compute):** Dữ liệu trải qua quá trình tổng hợp, làm sạch và xử lý để tuân thủ các tiêu chuẩn của doanh nghiệp, tổ chức. Bao gồm các tác vụ như chuyển đổi định dạng, nén dữ liệu, và phân vùng. Giai đoạn này sử dụng cả kỹ thuật xử lý batch processing và stream processing.
- **Sử dụng(Consume):** Dữ liệu đã xử lý được cung cấp để sử dụng thông qua các công cụ phân tích và trực quan hoá, kho dữ liệu vận hành, công cụ ra quyết định, khoa học dữ liệu, máy học,....

Đây là **cơ sở hạ tầng thực thi** cho CRISP-DM & Data Mining
Hầu hết hệ thống doanh nghiệp hiện đại đều áp dụng luồng này



Pipeline là “**công cụ và hệ thống phần mềm**”, còn CRISP-DM là “**tư duy phân tích**” – hai cái kết hợp thành Data Mining thực chiến.