

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI TP.HCM
VIỆN CÔNG NGHỆ THÔNG TIN VÀ ĐIỆN, ĐIỆN TỬ

DATA MINING

CHƯƠNG IV: PROCESSING

TS. Trần Thế Vinh




Xử lý dữ liệu

Processing là giai đoạn trung tâm trong data pipeline, nơi dữ liệu đã qua tiền xử lý (ready data) được đưa vào các thuật toán ML/DL/DM để khai phá mẫu, xu hướng, mối quan hệ tiềm ẩn.

Tại sao cần xử lý dữ liệu?

- Biến dữ liệu đã được chuẩn hoá thành tri thức hành động (predictive model, cluster structure, association rules).
- Giúp cá nhân, tổ chức ra quyết định dựa trên dữ liệu thay vì trực giác.
- Chuẩn bị artifact (mô hình, luật, profile) cho Evaluation và Deployment.

What is Data Processing?



Xây dựng module “Processing” trong Pipeline

Mục tiêu:

- Áp dụng kỹ thuật **Supervised Learning**:: Classification, Regression/Forecasting, **Unsupervised Learning**: Clustering, Association Rules, Dimensionality Reduction, **Specialized Tasks**: Anomaly Detection, Recommendation, Pattern Mining, NLP, Graph Mining, Deep Learning generative.
- Tạo ra mô hình, cụm, luật kết hợp → chuyển thành artifact có thể đánh giá và triển khai.
- Ghi lại đầy đủ metadata (siêu dữ liệu) và lineage (dòng chảy dữ liệu) để bảo đảm khả năng tái sử dụng và giải thích tường minh.

Work flow:

Ready Data → Data Split / Sampling → Feature Selection/ Dimensionality Reduction → Supervised/Unsupervised Learning, Specialized Tasks → Artifacts (Model, Cluster Profile, Rules,..) + Raw Metric

Input:


- Ready Data: dữ liệu đã được làm sạch, tích hợp, biến đổi và encoding
- Feature Views: tập đặc trưng đã được chuẩn hoá
- Config: tham số thuật toán, chiến lược chia tập train/val/test, tham số khai phá luật
- Metadata: version dataset, seed, data contract.

Output:

- Artifacts:
 - Supervised: Artifacts là mô hình dự đoán có gắn nhãn
 - Unsupervised: Artifacts là cụm, luật, cấu trúc ẩn trong dữ liệu
 - Specialized: Artifacts cho các tác vụ nâng cao như dự báo, phát hiện bất thường, gợi ý, xử lý văn bản,...
- Raw metric: logloss, AUC, silhouette score, số luật sinh ra,...
- Run Metadata: seed, dataset hash, hyperparameters.

Kết quả:

- Tạo ra tri thức có cấu trúc từ dữ liệu: mô hình dự đoán, cấu trúc cụm, tập luật kết hợp,...
- Chuẩn bị cho Evaluation (đánh giá độ chính xác, hữu ích, độ tin cậy)
- Lưu trữ artifact và metadata vào Model Registry / Data Lake House → sẵn sàng deployment.



Data Split / Sampling

Mục tiêu:

- Tạo ra tập Train / Validation / Test đúng ngữ cảnh dữ liệu; xử lý mất cân bằng và ràng buộc thực nghiệm

Input:


- Ready Data (đã clean/encode), split spec (holdout, TimeSeriesSplit), sampling policy (none/over/under/SMOTE), group/entity id (nếu cần gộp theo khách hàng/thiết bị)

Quy trình thuật toán:

- Schema và constraint check → khoá seed.
- Chia tập:
 - Stratified cho phân lớp mất cân bằng
 - Group phải phải giữ nguyên thực thể (user/device) trong cùng fold.
 - TimeSeriesSplit/walk-forward cho chuỗi thời gian (không trộn tương lai và quá khứ)
- Sampling (tùy chọn, chỉ trên Train): Random under/over, SMOTE/SMOTE-Tomek, hoặc class_weight thay thế.
- Ghi lại indices của từng tập

Artifacts/Output:

- Split_indices.parquet (train/val/test)
- Sampling_report.json (tỷ lệ lớp trước/sau, seed)
- Visualize: kích thước mỗi tập, imbalance ratio.



Feature Selection / Dimensionality Reduction

Mục tiêu:

- Chọn đặc trưng để tăng hiệu quả và giảm overfit; giữ pipeline tái sử dụng

Input:

- X_{train} , y_{train} (nếu supervised), feature metadata (kiểu dữ liệu, missing policy), cấu hình selector/dimred.

Quy trình thuật toán:

- Chuẩn hoá fit-on-train $\rightarrow$ transform cho Val/Test
- Feature Selection:
 - Filter: VarianceThreshold, corr/MI (ANOVA F-test, X^2), mRMR.
 - Embedded: L1/Lasso, ElasticNet, Tree/GBM importance, Boruta.
 - Wrapper: RFE/RFECV (có CV nội bộ)
- Dimensionality Reduction:
 - PCA/SVD (tabular, text TF-IDF), UMAP (cho trực quan/láng giềng), Autoencoder.
 - Lưu fitted transformer + feature_list
- Đối với text/image: lưu tokenizer/vocab hoặc preprocess graph (resize/nomalize)

Artifacts/Output:



- Preprocess_pipeline.pkl (scaler/encoder + selector + dimred)
- Selected_features.json, explained_variance.json (PCA), umap_params.json
- Log: thời gian fit, số chiều trước/sau



Supervised/Unsupervised Learning & Specialized Tasks

Mục tiêu:

- Hiểu và mô hình hoá dữ liệu: từ dữ liệu thô → tri thức
- Tối ưu hoá dự đoán/khám phá quy luật: dự đoán đúng (supervised), hoặc khám phá cấu trúc ẩn (unsupervised)
- Tạo ra artifact hữu ích: mô hình, cụm, luật, embedding,...
- Ứng dụng thực tiễn: dự báo, phân loại, khuyến nghị, phát hiện gian lận, hiểu hành vi người dùng,....



Supervised/Unsupervised Learning & Specialized Tasks

1. Supervised Learning (Classification/Regression)

- **Mục tiêu**
 - Huấn luyện mô hình dự đoán với HPO & CV, có calibration/ngưỡng nếu cần.
- **Input**
 - Dữ liệu đã transform theo pipeline, `split_indices`, `algo_list` (LR/SVM/XGBoost/LightGBM/CatBoost/NN), `HPO_spec`, `metrics`.
- **Quy trình/Thuật toán**
 - **CV**: Stratified K-fold (phân lớp), `TimeSeriesSplit` (chuỗi).
 - **HPO**: Random/Bayesian (TPE), **early stopping**.
 - **Class imbalance**: `class_weight`, focal loss, threshold tuning theo **PR-AUC/F1**.
 - **Calibration**: Platt/Isotonic trên hold-out.
 - **Explainability**: SHAP (tree/kernel), permutation importance.
- **Artifacts/Output**
 - `model.pkl/model.onnx`, `calibrator.pkl`, `thresholds.json`, `feature_importance.parquet`, `shap_values.parquet`.
 - Dự đoán theo fold: `oof_predictions.parquet`, `val_predictions.parquet`.
 - **Raw metrics** per fold: `roc_auc`, `pr_auc`, `f1`, `logloss`, thời gian huấn luyện.

Supervised/Unsupervised Learning & Specialized Tasks

2. Unsupervised Learning

• Clustering

• Mục tiêu

- Khai phá cấu trúc nhóm/segment; tạo hồ sơ cụm.

• Quy trình

- Chọn thuật toán theo dữ liệu: **KMeans/mini-batch**, **GMM**, **DBSCAN/HDBSCAN**, **Spectral**.
- Xác định **k**: Elbow (SSE), **Silhouette**, Calinski-Harabasz, Davies-Bouldin.
- Với cao chiều: **PCA** → **KMeans** (fit PCA trên train).
- Tạo **Cluster Profile**: size, trung bình/độ lệch chuẩn, top-terms (TF-IDF), medoids/đại diện.

• Artifacts/Output

- clusterer.pkl, centroids.parquet/gmm_params.json, labels.parquet, cluster_profiles.parquet.
- Raw metrics: silhouette, ch_score, db_score.

• Association Rules

• Mục tiêu

- Tìm luật đồng xuất hiện có ý nghĩa.

• Quy trình

- **FP-Growth/Apriori** với minsup, minconf, minlift.
- Prune luật dư thừa (subsumption), lọc theo **leverage/conviction**.
- Ràng buộc domain (cấm/ép cặp).

• Artifacts/Output

- rules.parquet (X, Y, support, confidence, lift, leverage, conviction), itemsets.parquet, dictionary.json.
- Raw metrics: số luật, phân bố lift, thời gian khai phá.

Supervised/Unsupervised Learning & Specialized Tasks

3. Specialized Tasks

- **Forecasting (Time Series)**
 - **Quy trình**
 - **Backtesting** (sliding/expanding window), giữ mùa vụ.
 - Mô hình: ARIMA/SARIMA, Prophet, **XGBoost + features thời gian**, LSTM/Temporal CNN/Transformer.
 - Exogenous (xvars): kiểm tra trễ (lag), holiday/seasonal.
 - Metrics: **sMAPE**, **MAPE**, **RMSE**, **MAE**, pinball loss (quantile).
 - **Artifacts/Output**
 - forecast_model.pkl, backtests.parquet, forecast.parquet (khoảng tin cậy), feature_gen.yaml.
- **Anomaly Detection**
 - Thuật toán: **Isolation Forest**, One-Class SVM, Autoencoder.
 - Ngưỡng: theo **contamination** hoặc **P@k** mong muốn.
 - Output: anomaly_scores.parquet, threshold.json, anomalies.parquet.
- **Recommendation**
 - Matrix Factorization (ALS), NCF/Two-Tower, GNN.
 - Offline metrics: **Recall@k**, **MAP@k**, **NDCG@k**; negative sampling.
 - Output: user_factors.parquet, item_factors.parquet, rec_lists.parquet.
- **NLP / Graph (tùy bài toán)**
 - NLP: embedding (BERT), topic (LDA), text classifier; lưu tokenizer, vocab, label_map.
 - Graph: community (Louvain), embeddings (Node2Vec, GCN); lưu graph.bin, embeddings.parquet.

Artifacts (Model, Cluster Profile, Rules, ...) + Raw Metrics

- Artifacts chuẩn hóa (lưu trên Data Lake version theo run_id)
- Raw Metrics (để Evaluation)
 - Per-fold/per-window: metrics.parquet (metric, value, fold/window, seed, timestamp).
 - Logs Metric tool: thời gian huấn luyện, GPU/CPU/RAM, I/O MinIO; Grafana dashboard processing_runs.
- Lineage/Metadata (DB Storage)
 - TrainingRun: run_id, dataset_version hash, feature_view, git_commit, docker_image, seed.
 - Liên kết **một-nhiều** tới Artifacts + Metrics.

```
s3://minio/artifacts/processing/{project}/{run_id}/
preprocess/
  pipeline.pkl
  selected_features.json
  pca_params.json
supervised/
  model.pkl | model.onnx
  calibrator.pkl
  thresholds.json
  feature_importance.parquet
  shap_values.parquet
  oof_predictions.parquet
  val_predictions.parquet
clustering/
  clusterer.pkl
  centroids.parquet
  labels.parquet
  cluster_profiles.parquet
assoc_rules/
  rules.parquet
  itemsets.parquet
  dictionary.json
forecasting/
  forecast_model.pkl
  backtests.parquet
  forecast.parquet
anomaly/
  detector.pkl
  anomaly_scores.parquet
  anomalies.parquet
recommendation/
  user_factors.parquet
  item_factors.parquet
  rec_lists.parquet
metadata/
  run_config.yaml
  dataset_version.json
  split_indices.parquet
  lineage.json
```