Chương 4.

Data Preparation – Chuẩn bị dữ liệu



PhD. Nguyễn Thị Khánh Tiên
tiennkt@ut.edu.vn

Mục tiêu: Hiểu các kỹ thuật xử lý và biến đổi dữ liệu để sẵn sàng cho mô hình.

Sau khi hoàn thành chương này, sinh viên có thể:

- Hiểu vai trò và các bước của **Data Preparation** trong CRISP-DM.
- Thực hiện **làm sạch dữ liệu (Data Cleaning)**: xử lý giá trị thiếu, dữ liệu trùng, dữ liệu nhiễu.
- Thực hiện **biến đổi dữ liệu (Data Transformation)**: chuẩn hóa, mã hóa, rút trích đặc trưng.
- Áp dụng **Feature Engineering** để tối ưu cho mô hình.
- Xây dựng pipeline chuẩn bị dữ liệu bằng Python.

Nội dung chính:

- Làm sạch dữ liệu (missing, outlier, duplicate).
- Mã hóa biến, chuẩn hóa, rút trích đặc trưng.
- Feature Engineering (biến đổi log, tạo biến tương tác, PCA).
- Chia tập train/test, lưu pipeline.
- Thực hành: xử lý dữ liệu khách hàng hoặc dữ liệu y tế.

Vai trò của giai đoạn Data Preparation

- Loại bỏ sai lệch, làm dữ liệu đồng nhất, có chất lượng cao.
- Tạo đặc trưng phù hợp cho mô hình học máy.
- Đảm bảo dữ liệu có thể đưa vào thuật toán (Machine Learning Ready).

Các bước chính trong Data Preparation	Nội dung	Kết quả đầu ra
1. Data Cleaning	Làm sạch dữ liệu: xử lý giá trị thiếu, trùng, nhiễu, ngoại lai	Dữ liệu sạch
2. Data Transformation	Biến đổi dữ liệu về dạng phù hợp	Dữ liệu đã chuẩn hóa
3. Feature Engineering	Tạo và chọn đặc trưng quan trọng	Dữ liệu tối ưu cho mô hình

LÀM SẠCH DỮ LIỆU (DATA CLEANING)



Xử lý giá trị thiếu (Missing Values)



Phát hiện và xử lý ngoại lai (Outliers)



Xử lý dữ liệu nhiễu (Noise)

BIẾN ĐỔI DỮ LIỆU (DATA TRANSFORMATION)



Chuẩn hóa dữ liệu (Normalization / Scaling)



Mã hóa dữ liệu phân loại (Encoding)

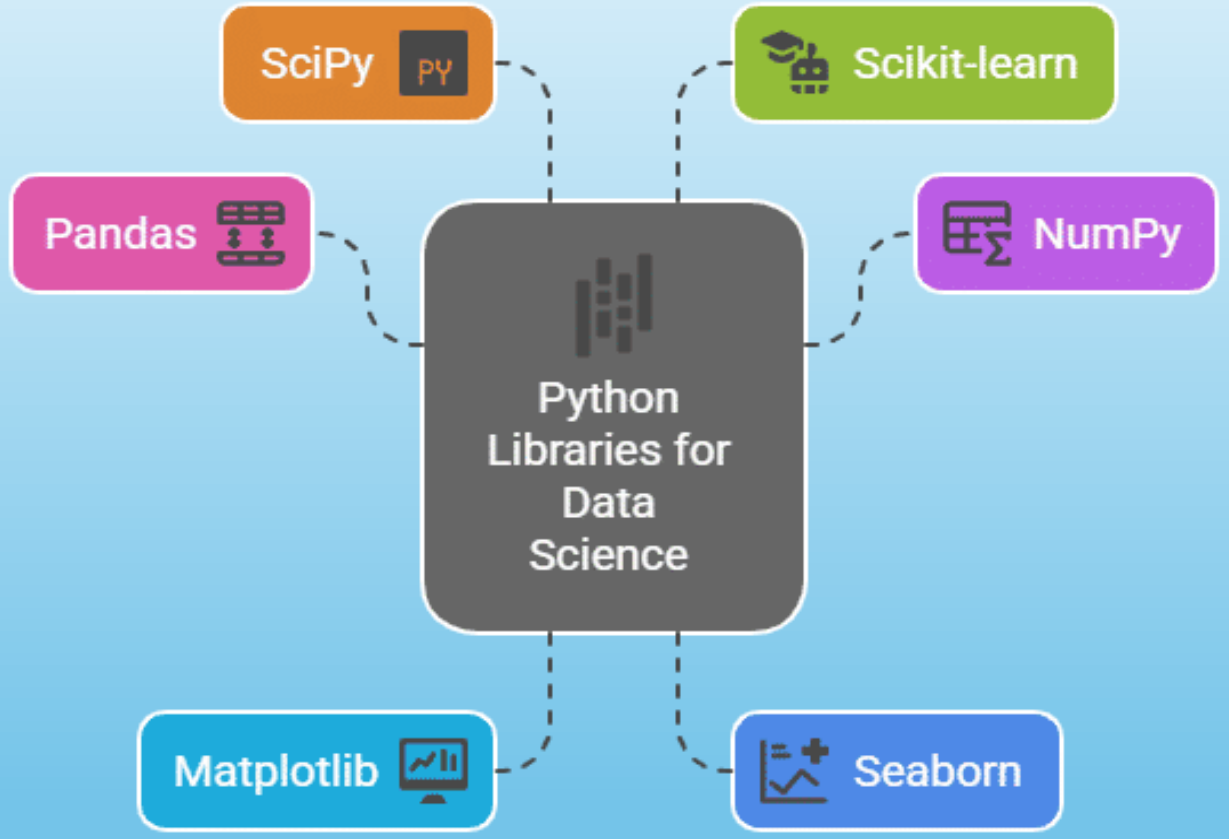


Rút trích đặc trưng (Feature Extraction)

KỸ THUẬT FEATURE ENGINEERING

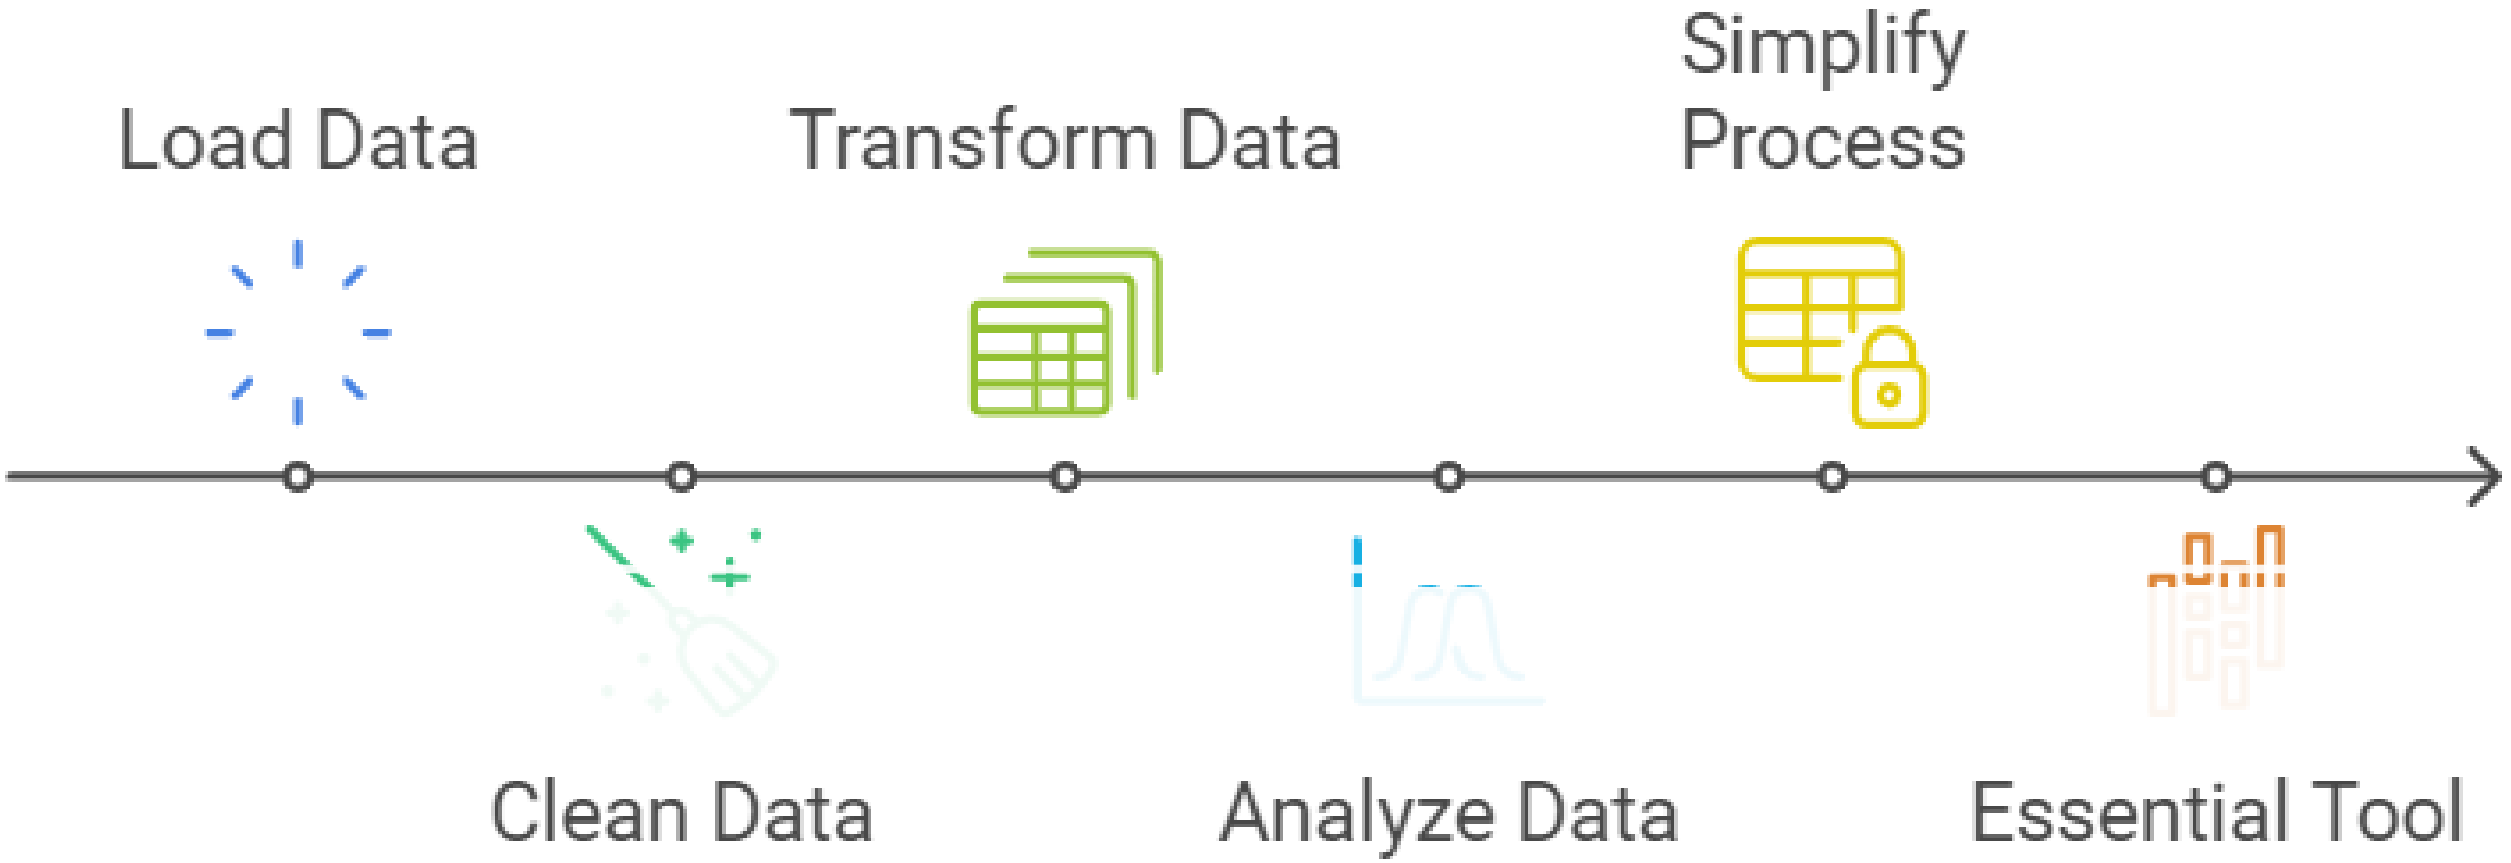
Tạo đặc trưng mới

Chọn đặc trưng quan trọng (Feature Selection)



https://www.youtube.com/watch?v=2uvysYbKdjM

Pandas DataFrame Operations



CÂU HỎI ÔN TẬP

Mục tiêu của giai đoạn Data Preparation là gì?
Phân biệt “Data Cleaning” và “Data Transformation”.
Khi nào nên dùng Min-Max scaling, khi nào nên dùng Standard scaling?
So sánh One-Hot và Label Encoding.
Giải thích tại sao Feature Engineering có thể cải thiện hiệu năng mô hình