Chương 5.

Modeling – Xây dựng mô hình



PhD. Nguyễn Thị Khánh Tiên
tiennntk@ut.edu.vn

Mục tiêu: Giới thiệu và thực hành các thuật toán khai thác dữ liệu.

Sau khi hoàn thành chương này, sinh viên có thể:

- Hiểu vai trò của giai đoạn **Modeling** trong quy trình CRISP-DM.
- Biết cách **chọn thuật toán** phù hợp với loại bài toán (phân loại, hồi quy, phân cụm...).
- Thực hiện **huấn luyện mô hình** bằng Python (scikit-learn).
- Áp dụng các kỹ thuật **chia tập dữ liệu**, **cross-validation** và **tinh chỉnh siêu tham số**.
- Đánh giá mô hình ban đầu bằng các chỉ số định lượng.

Nội dung chính:

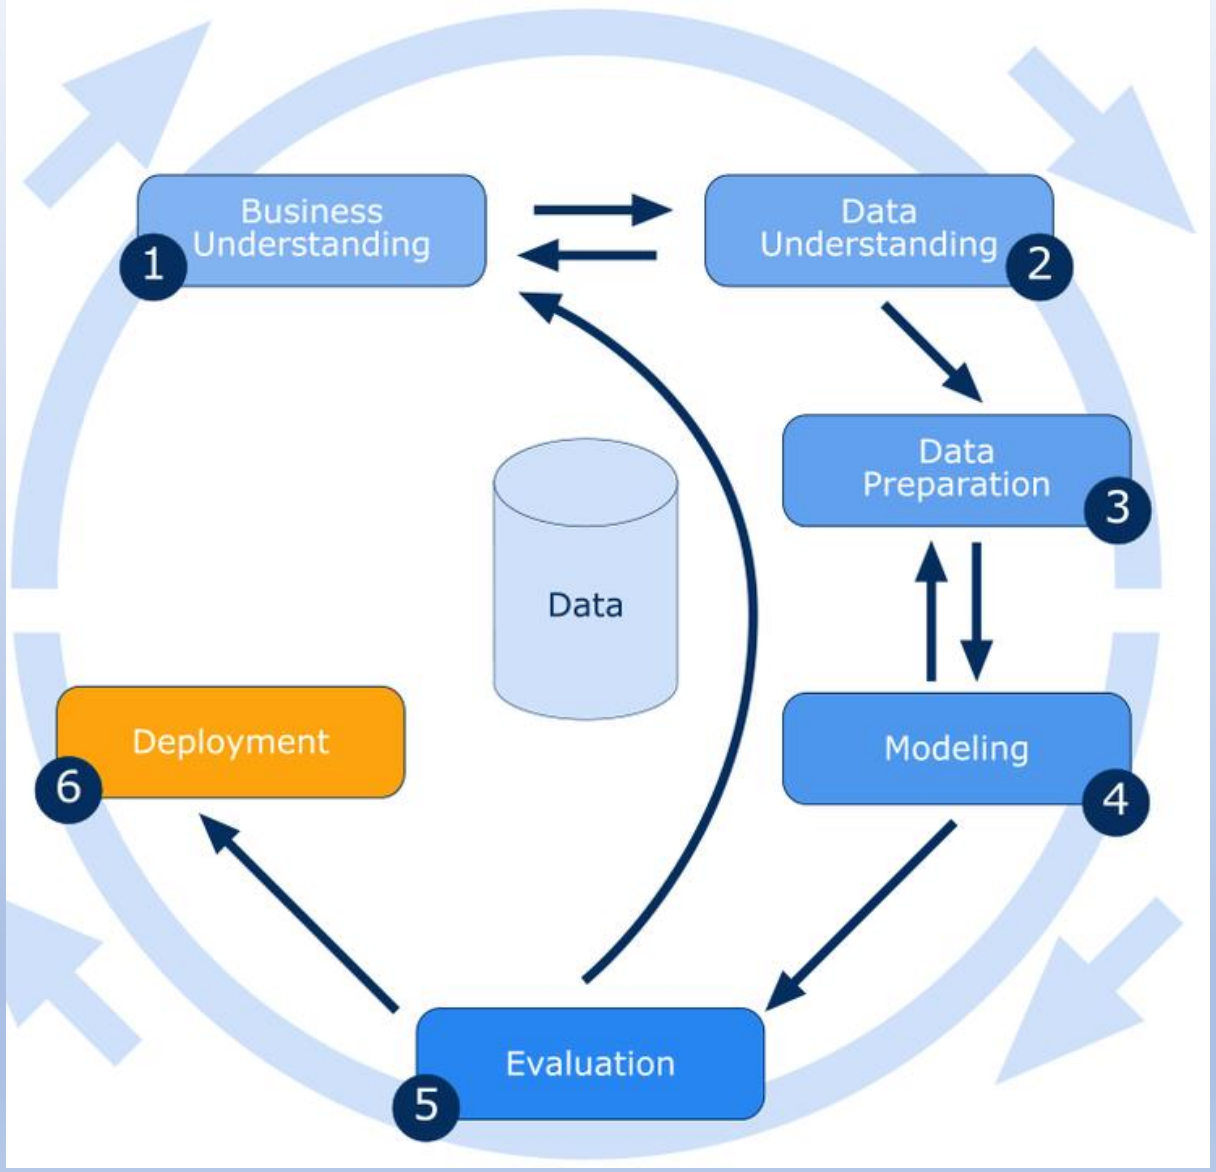
1. Phân loại (Decision Tree, Random Forest, Logistic Regression, SVM).
2. Hồi quy (Linear/Polynomial Regression).
3. Phân cụm (K-Means, Hierarchical Clustering).
4. Kết hợp mô hình và đánh giá chéo.
5. Dùng thư viện: scikit-learn.
6. Bài thực hành: mô hình dự đoán thu nhập/khách hàng rời bỏ.

Vai trò của giai đoạn Modeling

Trong CRISP-DM, Mo deling là bước huấn luyện và thử nghiệm các mô hình học máy để tìm ra mô hình tốt nhất cho bài toán thực tế.

Quá trình này thường gồm các bước sau:

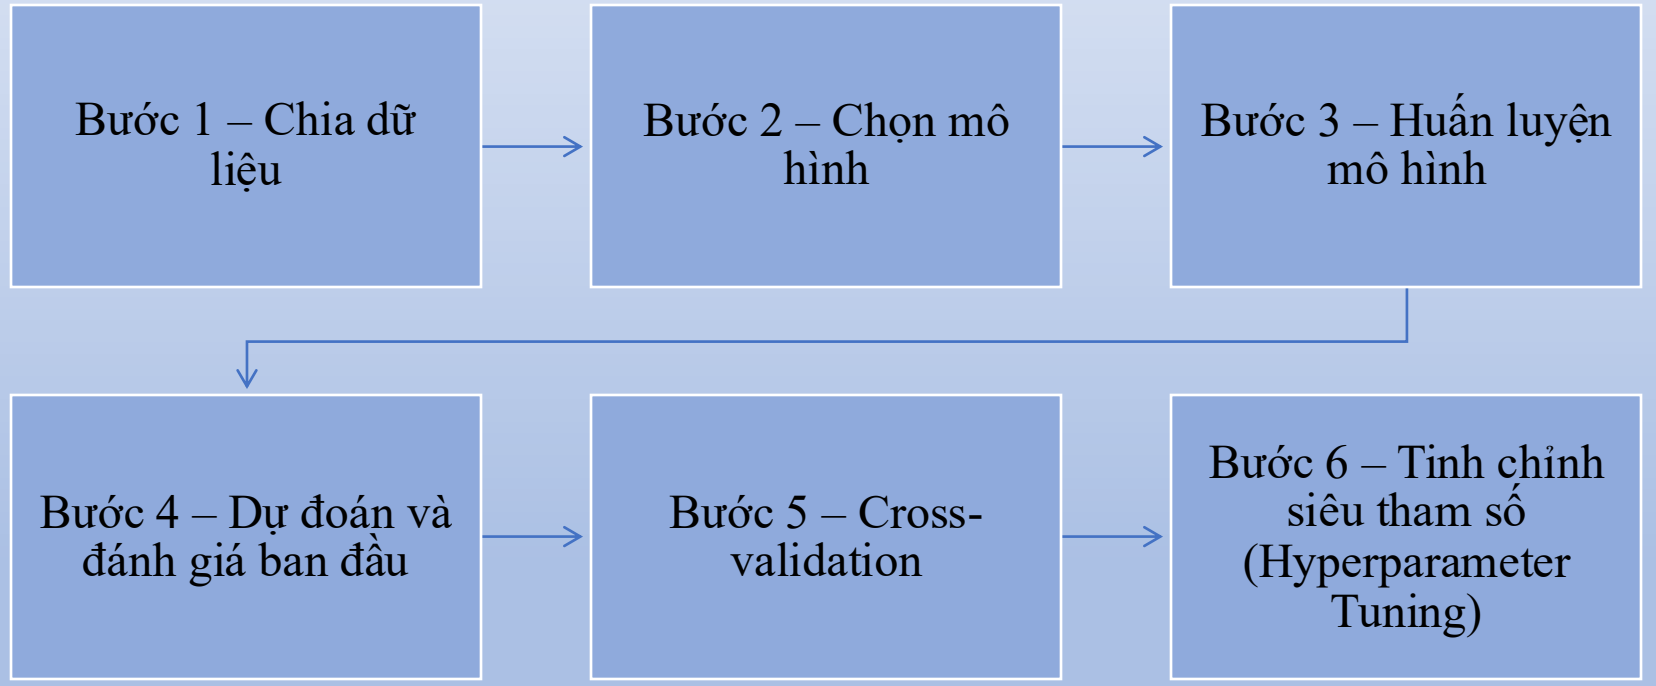
Chọn mô hình phù hợp với dạng bài toán.	**Huấn luyện mô hình** trên tập train.	**Đánh giá hiệu quả** bằng tập test hoặc cross-validation.	**Điều chỉnh tham số** để tối ưu hóa hiệu năng.



CÁC LOẠI BÀI TOÁN TRONG DATA MINING

Loại bài toán	Mô tả	Thuật toán thường dùng	Biến mục tiêu
Phân loại (Classification)	Dự đoán nhãn (dạng rời rạc)	Logistic Regression, Decision Tree, Random Forest, SVM, KNN	Categorical
Hồi quy (Regression)	Dự đoán giá trị (liên tục)	Linear Regression, Lasso, Ridge, XGBoost	Continuous
Phân cụm (Clustering)	Nhóm dữ liệu tương đồng	K-Means, DBSCAN, Hierarchical Clustering	Không có
Phát hiện bất thường (Anomaly Detection)	Xác định điểm dữ liệu khác biệt	Isolation Forest, One-Class SVM	-
Luật kết hợp (Association Rule)	Tìm mối quan hệ giữa các mục	Apriori, FP-Growth	-

QUY TRÌNH XÂY DỰNG MÔ HÌNH

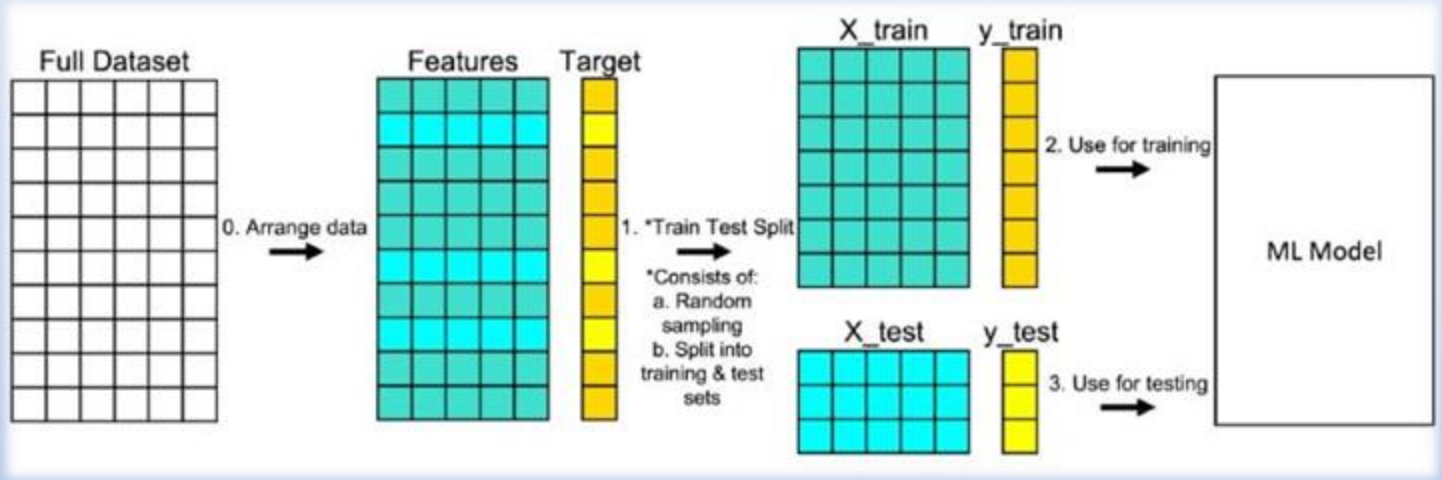


Bước 1.

Chia dữ liệu

- Chia dữ liệu thành **train** (để học) và **test** (để kiểm tra mô hình)
- Thông thường: 70–80% train, 20–30% test.

  Với dữ liệu nhỏ: có thể thêm **validation set** hoặc dùng **cross-validation**.



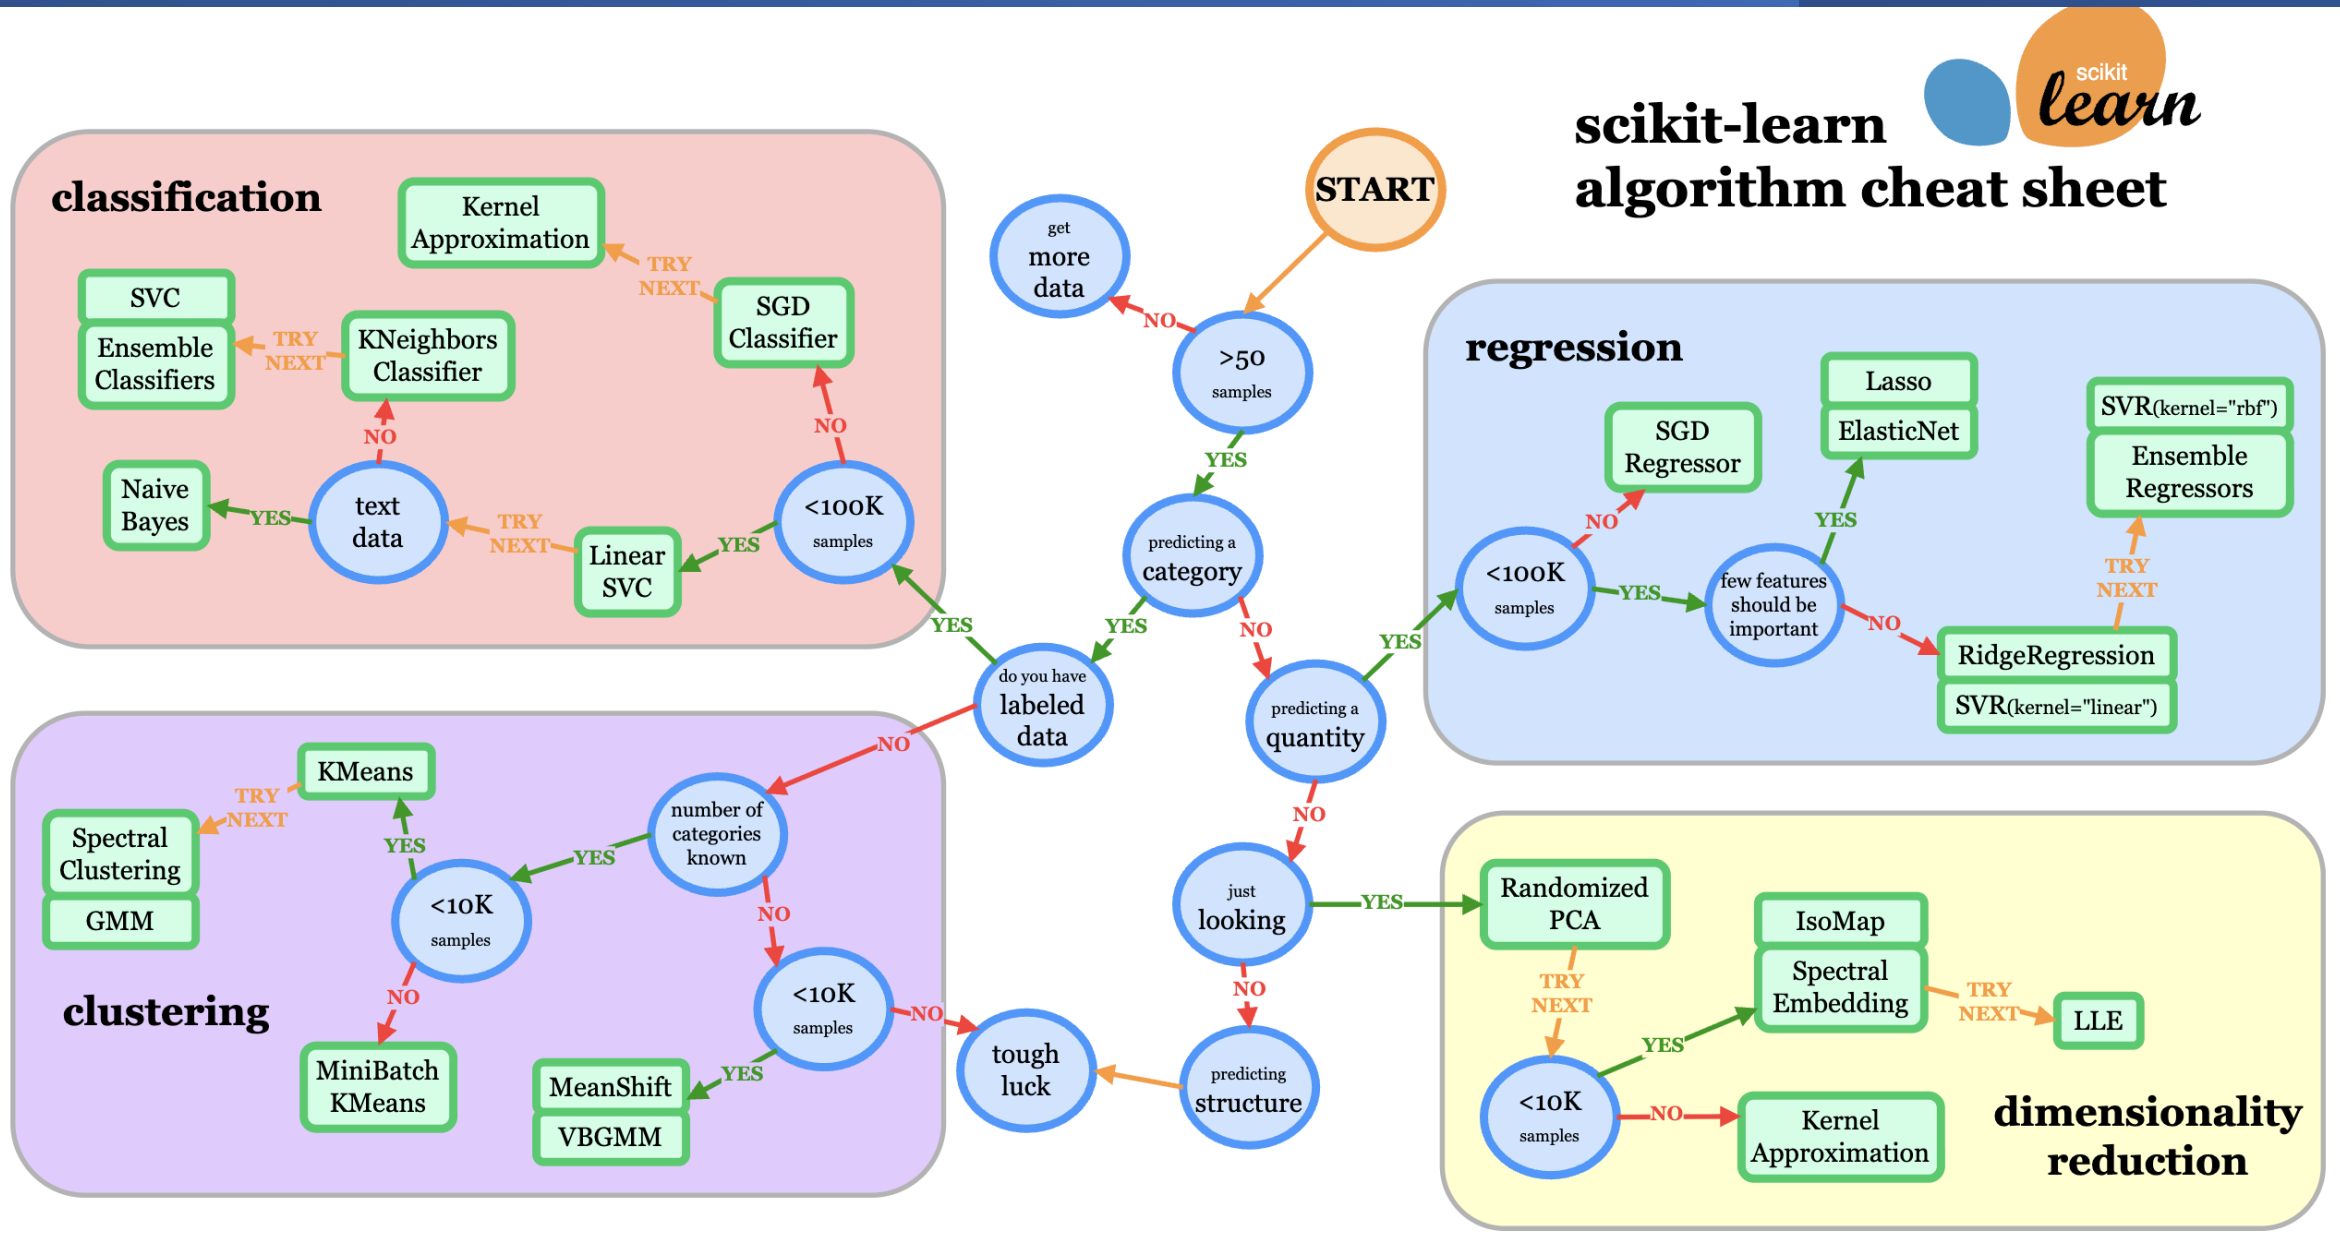

```
from sklearn.model_selection import train_test_split
X = df.drop('label', axis=1)
y = df['label']
X_train, X_test, y_train, y_test = train_test_split(X,
y, test_size=0.2, random_state=42)
```

Bước 2.

Chọn mô hình

Loại	Thuật toán tiêu biểu	Ưu điểm	Nhược điểm
Phân loại	Logistic Regression	Dễ hiểu, nhanh	Giả định tuyến tính
Phân loại	Decision Tree	Giải thích tốt, xử lý phi tuyến	Dễ overfit
Phân loại	Random Forest	Hiệu suất cao, giảm overfit	Khó giải thích
Hồi quy	Linear Regression	Dễ triển khai	Không phù hợp dữ liệu phi tuyến
Hồi quy	Random Forest Regressor	Mạnh, phi tuyến	Chậm với dữ liệu lớn
Phân cụm	K-Means	Đơn giản, nhanh	Phải biết số cụm trước

scikit-learn algorithm cheat sheet



Bước 3.

Huấn luyện mô hình

```
from sklearn.tree import DecisionTreeClassifier
model = DecisionTreeClassifier(max_depth=5, random_state=42)
model.fit(X_train, y_train)
```

Bước 4.

Dự đoán và đánh giá ban đầu

```
y_pred = model.predict(X_test)
from sklearn.metrics import accuracy_score, confusion_matrix
print("Accuracy:", accuracy_score(y_test, y_pred))
print("Confusion Matrix:\n", confusion_matrix(y_test, y_pred))
```

Bước 5.

Cross-validation

```
from sklearn.model_selection import cross_val_score
from sklearn.ensemble import RandomForestClassifier
rf = RandomForestClassifier(n_estimators=100, random_state=42)
scores = cross_val_score(rf, X, y, cv=5)
print("Cross-validation Accuracy:", scores.mean())
```

Bước 6.

Tinh chỉnh siêu tham số

```
from sklearn.model_selection import GridSearchCV
param_grid = {'max_depth': [3, 5, 7], 'min_samples_split': [2, 5, 10]}
grid = GridSearchCV(DecisionTreeClassifier(), param_grid, cv=5)
grid.fit(X_train, y_train)
print("Best parameters:", grid.best_params_)
```

Phân loại (Classification)

Phân loại (Classification) là một kỹ thuật **học có giám sát (supervised learning)** được sử dụng để **dự đoán nhãn hoặc loại (category/class)** của các điểm dữ liệu mới dựa trên **tập dữ liệu huấn luyện đã được gán nhãn**.

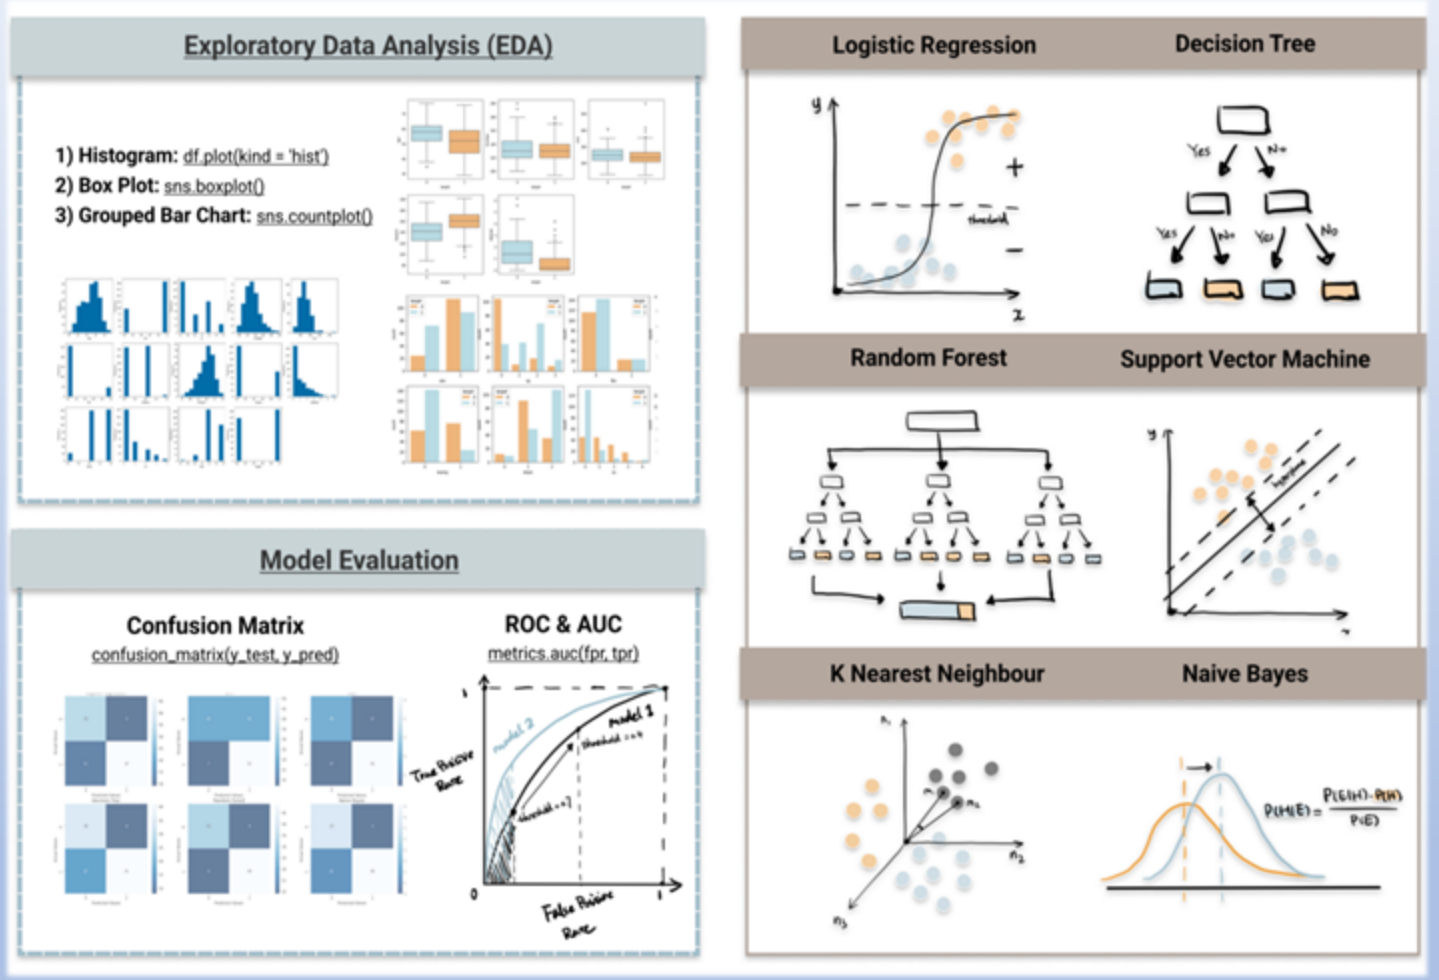
Trong quá trình phân loại, mô hình sẽ **học các mẫu (patterns)** từ dữ liệu huấn luyện để **phân loại các quan sát mới** vào **những nhóm hoặc lớp đã được xác định trước**.

Hai loại bài toán phân loại chính:

- **Phân loại nhị phân (Binary Classification):** Dự đoán kết quả chỉ có **hai lớp** khả thi (ví dụ: thư rác hoặc không, nam hoặc nữ, có hoặc không).
- **Phân loại đa lớp (Multi-class Classification):** Dự đoán kết quả có **hơn hai lớp** (ví dụ: phân loại các loại cây trồng, phân loại thể loại âm nhạc).

Ứng dụng của các thuật toán phân loại

- **Y tế (Healthcare):** Chẩn đoán bệnh dựa trên triệu chứng hoặc kết quả xét nghiệm.
- **Tài chính (Finance):** Phát hiện gian lận trong giao dịch.
- **Marketing:** Phân khúc khách hàng theo hành vi hoặc đặc điểm.
- **Xử lý ảnh (Image Processing):** Nhận dạng đối tượng trong hình ảnh.



Hồi quy (Regression)

Hồi quy (Regression) là một phương pháp thống kê được sử dụng để mô hình hóa mối quan hệ giữa **biến phụ thuộc** (kết quả đầu ra) và **một hoặc nhiều biến độc lập** (các yếu tố dự đoán). Trong **học máy (machine learning)**, các thuật toán hồi quy được dùng để **dự đoán các giá trị số liên tục**.

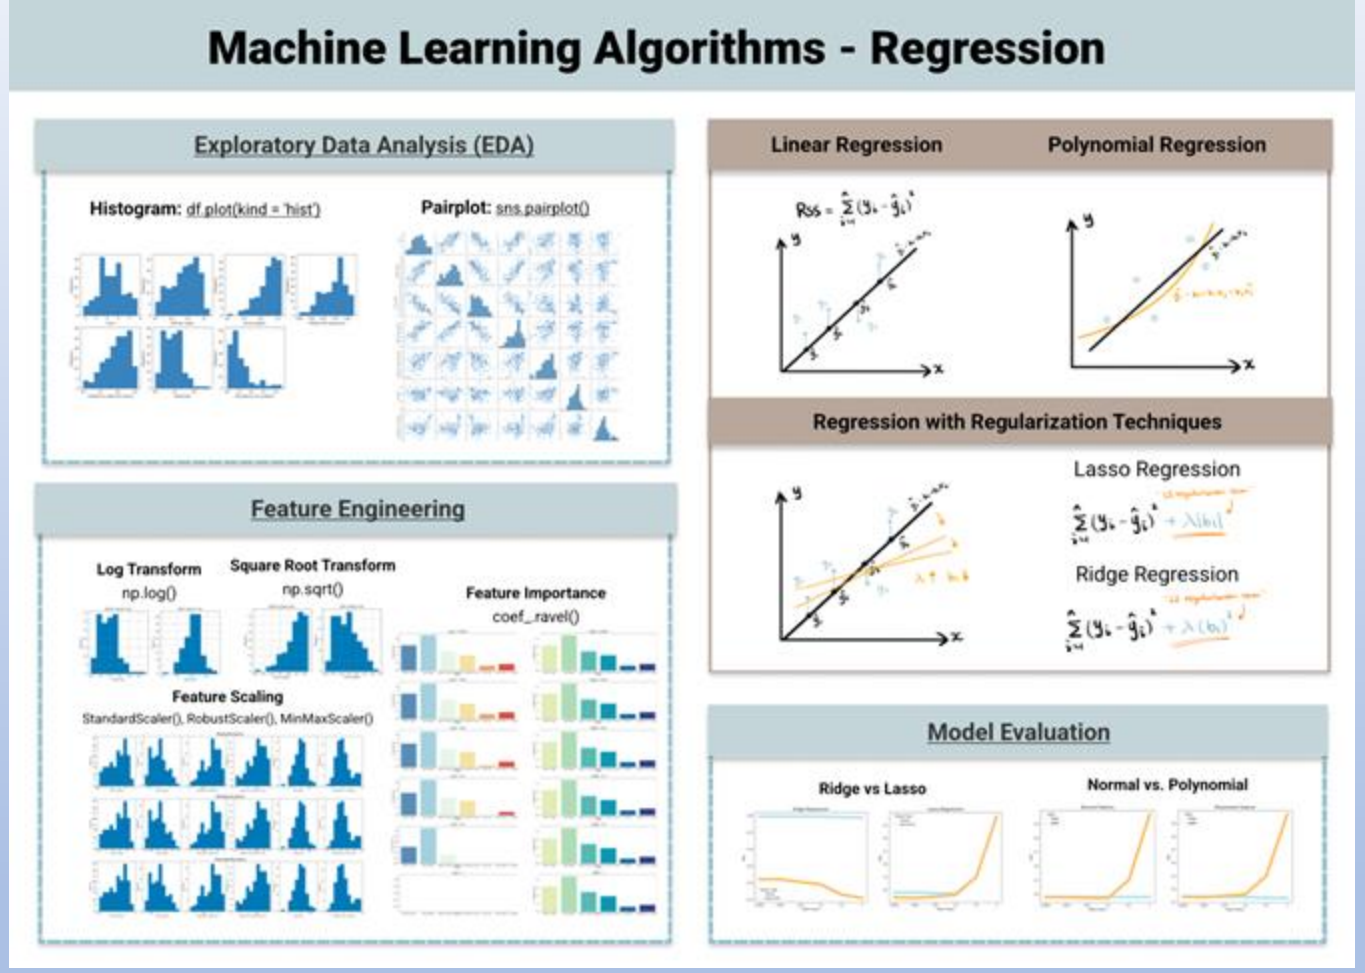
Các chỉ số đánh giá mô hình hồi quy (Regression Evaluation Metrics) được sử dụng để đo lường hiệu suất của mô hình, bao gồm:

- **MSE**– sai số bình phương trung bình
- **RMSE**– căn bậc hai của MSE
- **MAE**– sai số tuyệt đối trung bình
- **MAPE** – sai số phần trăm tuyệt đối trung bình

Những chỉ số này giúp **đánh giá mức độ sai lệch giữa giá trị dự đoán và giá trị thực tế** của mô hình.

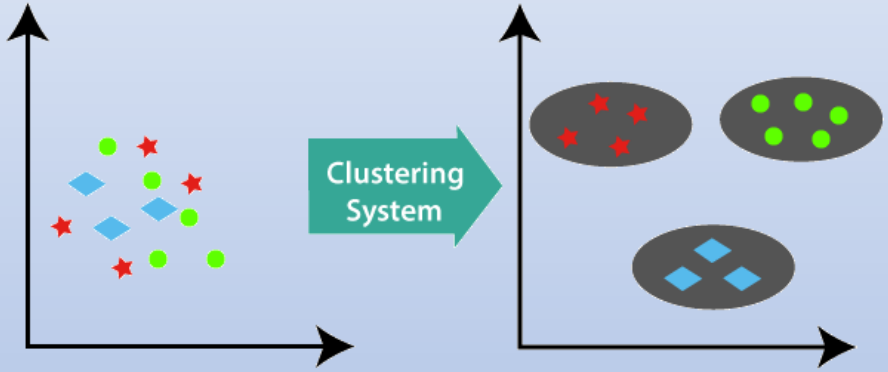
Ứng dụng của hồi quy

- Dự đoán doanh số bán hàng
- Dự đoán giá cổ phiếu
- Dự báo nhu cầu
- Dự đoán giá bất động sản
- Dự đoán giá trị vòng đời khách hàng



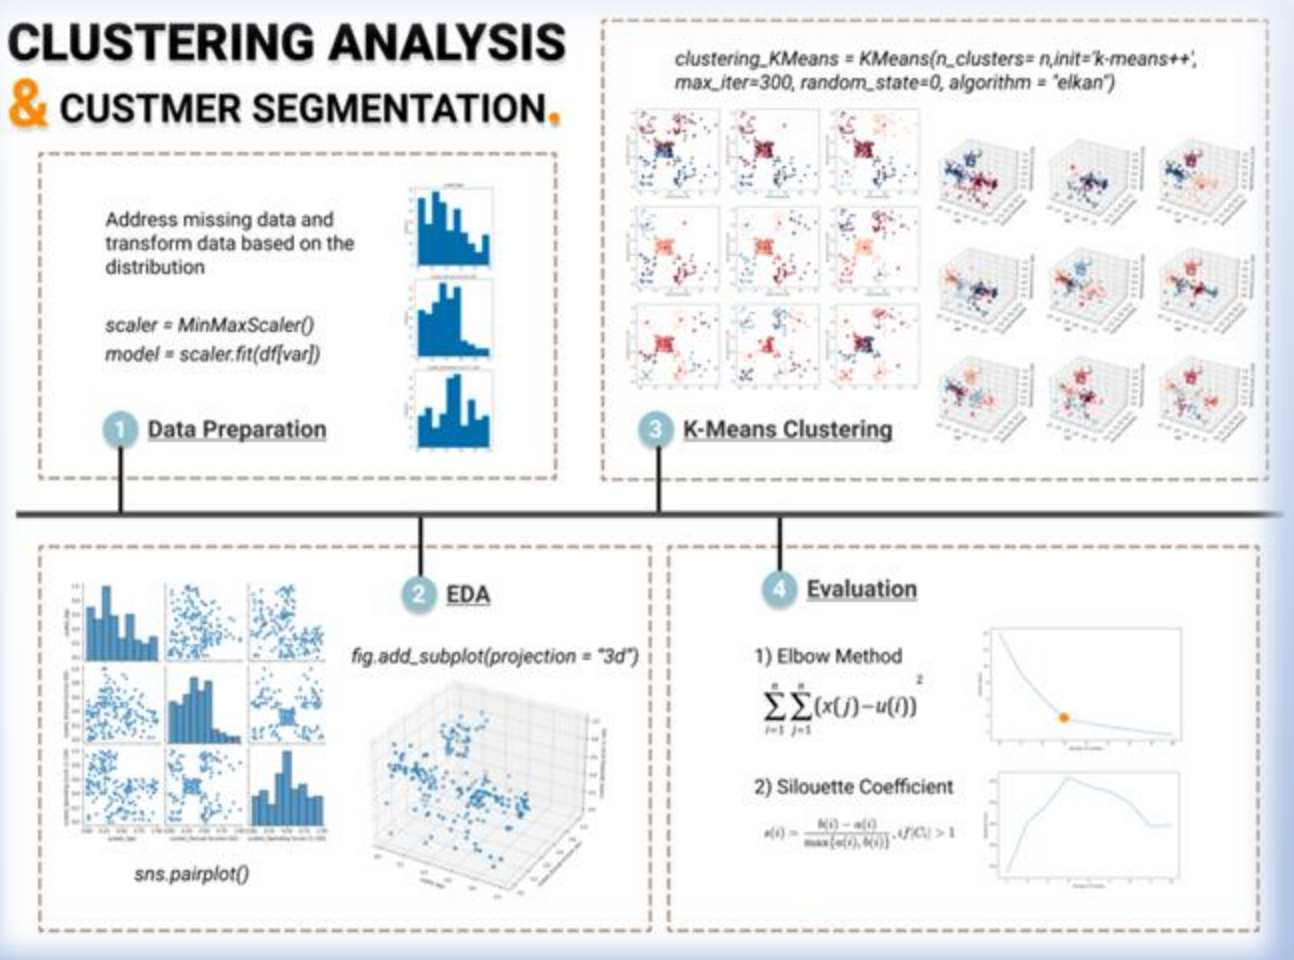
Phân cụm (Clustering)

Phân cụm (Clustering) là một kỹ thuật trong học máy (machine learning) được sử dụng để nhóm các điểm dữ liệu tương tự nhau thành từng cụm (nhóm). Thuật toán tự động phát hiện các mẫu (patterns) hoặc cấu trúc tự nhiên trong dữ liệu mà không cần có nhãn trước. Nói cách khác, phân cụm giúp chia dữ liệu thành các nhóm sao cho các điểm trong cùng một nhóm có đặc điểm giống nhau, còn các nhóm khác nhau thì có sự khác biệt rõ rệt.



Ứng dụng của Phân cụm (Clustering Applications)

- Phân khúc khách hàng (Customer Segmentation): Nhóm các khách hàng lại với nhau dựa trên đặc điểm nhân khẩu học, hành vi mua hàng hoặc sở thích tiêu dùng.
- Phân đoạn ảnh (Image Segmentation): Chia một hình ảnh thành các vùng riêng biệt dựa trên màu sắc, kết cấu (texture) hoặc hình dạng.
- Phát hiện bất thường (Anomaly Detection): Xác định các điểm dữ liệu bất thường có sự khác biệt lớn so với phần còn lại của tập dữ liệu.
- Phân tích mạng xã hội (Social Network Analysis): Tìm ra các cộng đồng hoặc nhóm người dùng có mối liên hệ chặt chẽ trong mạng lưới.
- Tin sinh học (Bioinformatics): Phân tích mẫu biểu hiện gen hoặc cấu trúc protein để hiểu rõ hơn về các quá trình sinh học.



THỰC HÀNH: PHÂN LOẠI KHÁCH HÀNG RỜI BỎ

Bộ dữ liệu: Kaggle – Customer Churn Dataset

Mục tiêu: Dự đoán khách hàng có rời bỏ dịch vụ (churn) hay không.

Quy trình thực hiện:

- Chuẩn bị dữ liệu (từ Chương 4).
- Chọn các đặc trưng quan trọng: Tenure, MonthlyCharges, ContractType, InternetService, PaymentMethod.
- Chia train/test.
- Thử nghiệm mô hình: Logistic Regression, Random Forest, SVM.
- So sánh kết quả theo Accuracy, Precision, Recall, F1.

CÂU HỎI ÔN TẬP

Mục tiêu của giai đoạn Modeling là gì trong CRISP-DM?

Phân biệt giữa mô hình phân loại và hồi quy.

Tại sao cần chia dữ liệu thành train/test?

Cross-validation giúp ích gì cho quá trình đánh giá?

Hãy nêu ưu điểm và nhược điểm của Decision Tree và Random Forest.

Khi nào cần tinh chỉnh siêu tham số?



BÀI TẬP THỰC HÀNH

Bài tập 1 – Dự đoán giá nhà

Dataset: House Prices – Kaggle

Yêu cầu:

1. Chọn các biến đầu vào liên quan đến diện tích, số phòng, vị trí.
2. Chia dữ liệu train/test (80/20).
3. So sánh kết quả giữa Linear Regression và Random Forest Regressor bằng RMSE.

Bài tập 2 – Phân cụm khách hàng

Dataset: Mall Customers Dataset

Yêu cầu:

1. Chọn các biến: Annual Income, Spending Score.
2. Áp dụng K-Means clustering với k = 3–5.
3. Vẽ biểu đồ phân cụm và nhận xét nhóm khách hàng.

TÓM TẮT CHƯƠNG

Modeling là giai đoạn trung tâm của CRISP-DM: biến dữ liệu thành mô hình có khả năng dự đoán.

Các bước chính:

- Chia dữ liệu
- Chọn mô hình
- Huấn luyện
- Đánh giá
- Tinh chỉnh

Cross-validation giúp đánh giá mô hình ổn định hơn.

Hyperparameter tuning giúp cải thiện hiệu năng mà không cần thay đổi dữ liệu.

TÀI LIỆU THAM KHẢO

1. Han, Kamber & Pei – *Data Mining: Concepts and Techniques*.
2. Géron, Aurélien – *Hands-on Machine Learning with Scikit-Learn, Keras & TensorFlow*.
3. IBM – *CRISP-DM Process Model*.
4. scikit-learn.org – *Model Selection and Evaluation Guide*.
5. Kaggle datasets cho thực hành mô hình hóa.