Chương 5.

Modeling – Xây dựng mô hình (part 3)



PhD. Nguyễn Thị Khánh Tiên
tiennkt@ut.edu.vn

Hồi quy (Regression)

Hồi quy (Regression) là một phương pháp thống kê được sử dụng để mô hình hóa mối quan hệ giữa **biến phụ thuộc** (kết quả đầu ra) và **một hoặc nhiều biến độc lập** (các yếu tố dự đoán). Trong **học máy (machine learning)**, các thuật toán hồi quy được dùng để **dự đoán các giá trị số liên tục**.

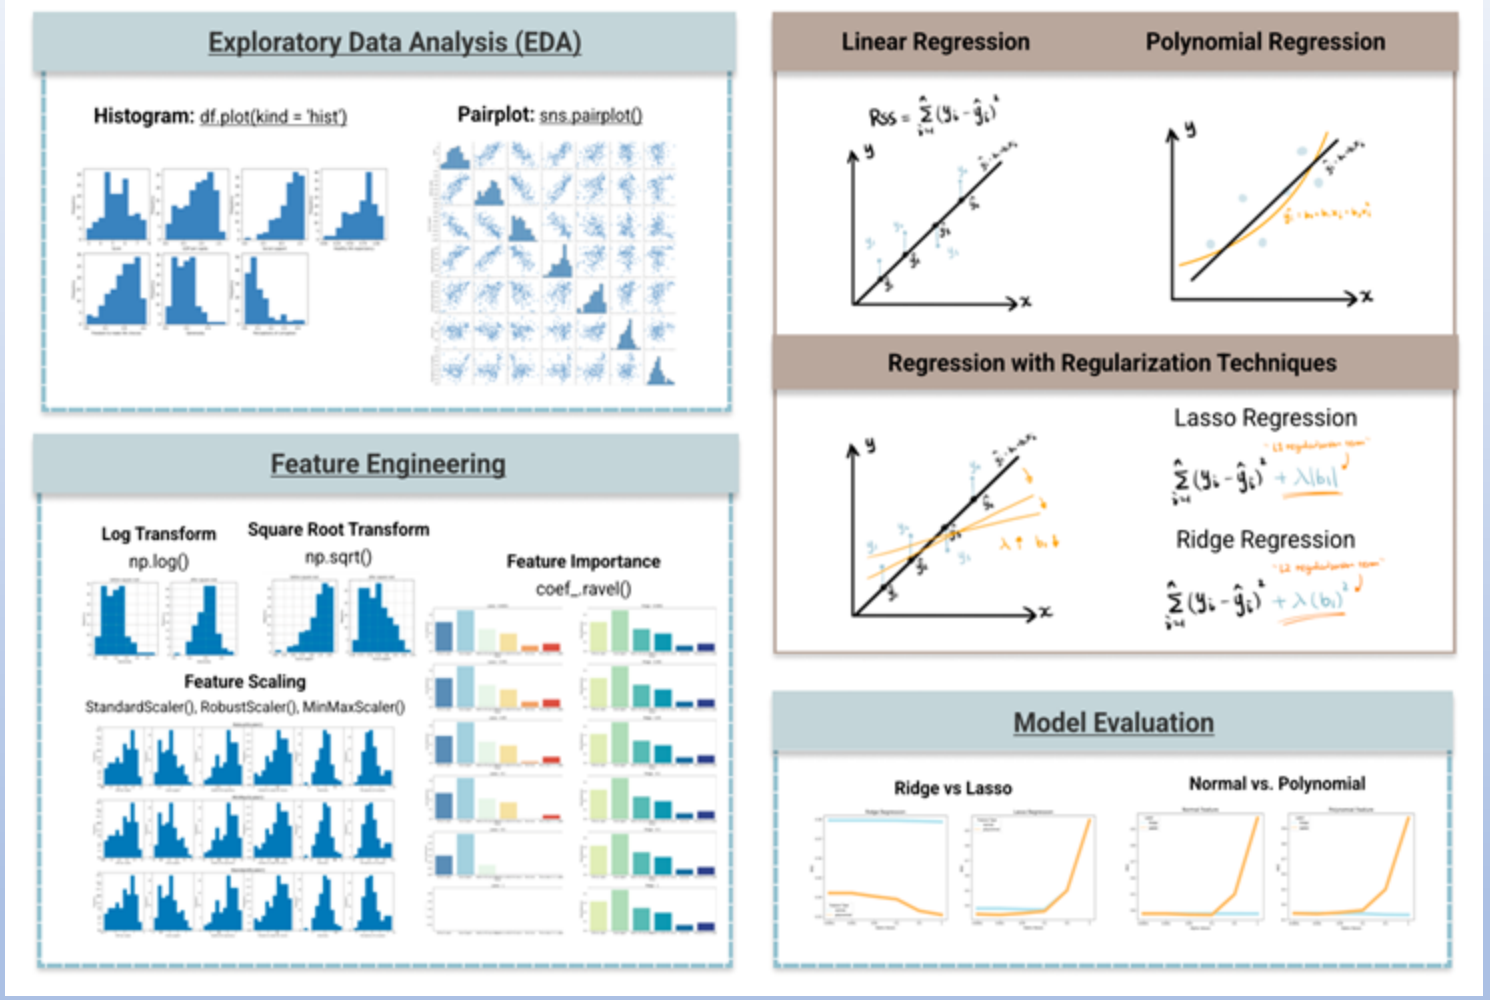
Các chỉ số đánh giá mô hình hồi quy (Regression Evaluation Metrics) được sử dụng để đo lường hiệu suất của mô hình, bao gồm:

- **MSE**– sai số bình phương trung bình
- **RMSE**– căn bậc hai của MSE
- **MAE**– sai số tuyệt đối trung bình
- **MAPE** – sai số phần trăm tuyệt đối trung bình

Những chỉ số này giúp **đánh giá mức độ sai lệch giữa giá trị dự đoán và giá trị thực tế** của mô hình.

Ứng dụng của hồi quy

- Dự đoán doanh số bán hàng
- Dự đoán giá cổ phiếu
- Dự báo nhu cầu
- Dự đoán giá bất động sản
- Dự đoán giá trị vòng đời khách hàng



Linear Regression: A Foundation in Machine Learning

Linear Regression is a statistical method used to model the relationship between a dependent variable (the outcome) and one or more independent variables (predictors). It assumes a linear relationship between the variables and aims to find the best-fitting line to represent this relationship.

The equation of a linear regression model is:

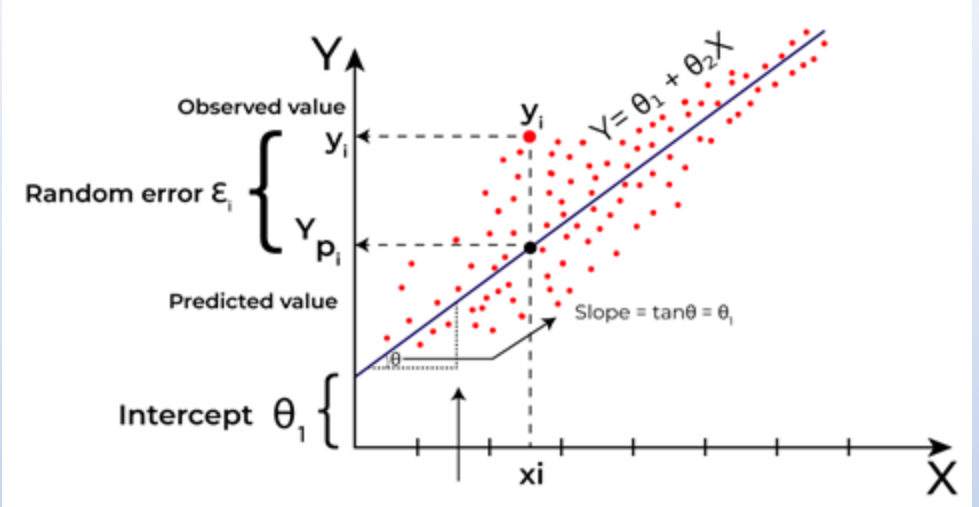
$$y = mx + b$$

where:

- y is the dependent variable (outcome)
- x is the independent variable (predictor)
- m is the slope of the line
- b is the y-intercept

Finding the Best-Fit Line. The goal of linear regression is to find the values of m and b that minimize the error between the predicted values and the actual values. This is often done using the least squares method, which calculates the line that minimizes the sum of the squared differences between the predicted and actual values.

- **Types of Linear Regression:**
- - Simple Linear Regression: Involves a single independent variable.
  - Equation: **y = mx + b**
  - Example: Predicting house prices based on the size of the house.
- - Multiple Linear Regression: Involves multiple independent variables.
  - Equation: **y = b0 + b1x1 + b2x2 + ... + bn*xn**
  - Example: Predicting car prices based on factors like mileage, age, brand, and features.



Using scikit-learn,

- LinearRegression https://scikit-learn.org/stable/modules/linear_model.html#ordinary-least-squares
- Linear Regression example https://scikit-learn.org/stable/auto_examples/linear_model/plot_ols.html#sphx-glr-auto-examples-linear-model-plot-ols-py
- A Comprehensive Guide to OLS Regression https://www.analyticsvidhya.com/blog/2023/01/a-comprehensive-guide-to-ols-regression-part-1/

Ordinary Least Squares (OLS)

Ordinary Least Squares (OLS) is the most common and simplest method of linear regression. It aims to find the best-fitting line that minimizes the sum of the squared differences between the predicted and actual values.

In OLS, the goal is to minimize the sum of squared residuals (SSR):

$$\mathbf{SSR = \Sigma(y_i - \hat{y}_i)^2}$$

where:

y_i - the observed value of the dependent variable.

$\hat{y}_i$ - the predicted value of the dependent variable.

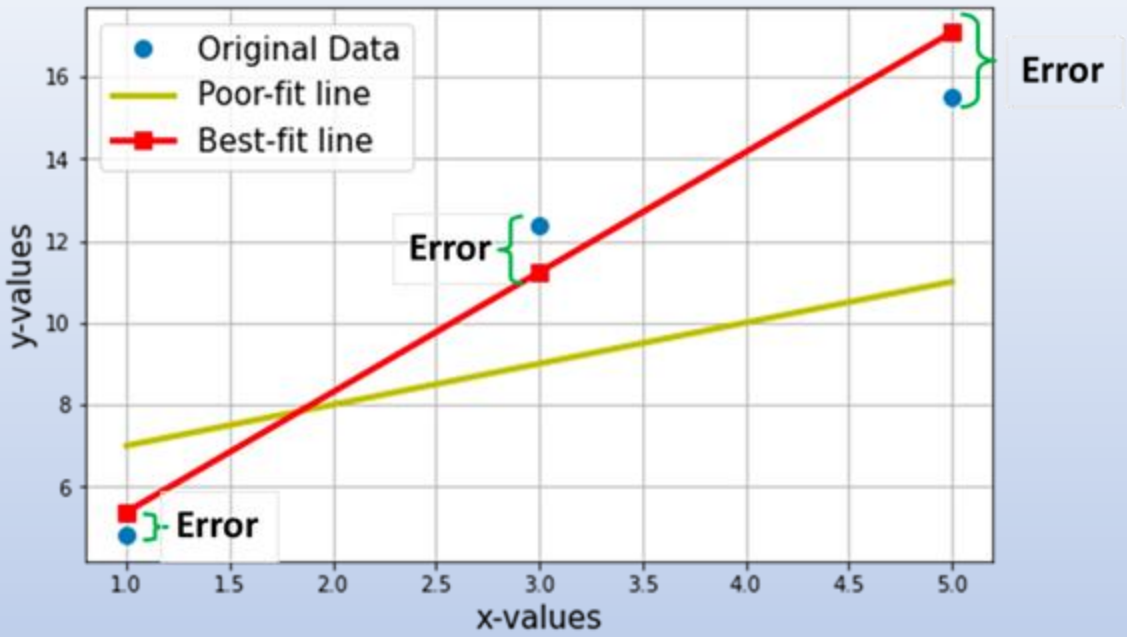
The OLS estimates of the regression coefficients (slope and intercept) are obtained by solving the following normal equations:

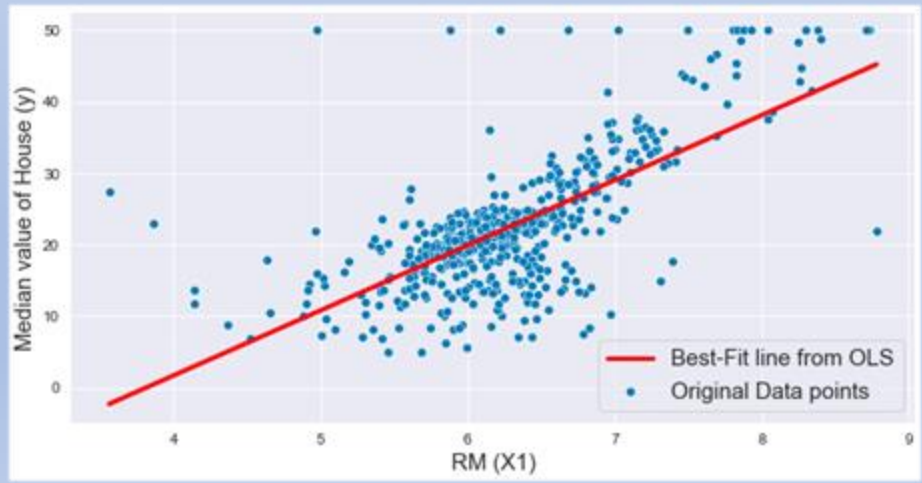
$$\min_w ||Xw - y||_2^2$$

Where, predicted value :

$$\hat{y}(w, x) = w_0 + w_1 x_1 + \ldots + w_p x_p$$

vector $w = (w_1, \ldots, w_p)$ as `coef_` and w_0 as `intercept_`.





Lasso Regression vs Ridge Regression

LASSO (Least Absolute Shrinkage and Selection Operator) and Ridge Regression are both regularization techniques used to prevent overfitting in linear regression models. While they share similarities, they have distinct characteristics and applications.

Feature	LASSO	Ridge Regression
Penalty Term	$\Sigma\|wj\|$	$\Sigma(wj^2)$
Feature Selection	Yes	No
Coefficient Shrinkage	Sets some coefficients to zero	Shrinks all coefficients towards zero
Bias-Variance Trade-off	Higher bias, lower variance	Lower bias, higher variance

Using scikit-learn,
→ Laso Regression
https://scikit-learn.org/1.5/modules/linear_model.html#lasso
→ Rigdge Regression
https://scikit-learn.org/1.5/modules/linear_model.html#regression
→ Practice
https://www.datacamp.com/tutorial/tutorial-lasso-ridge-regression

When to Use Which

- LASSO:
- When feature selection is desired.
- When the true model is believed to be sparse (has many zero coefficients).

- Ridge Regression:
- When all features are believed to be relevant.
- When overfitting is a concern and feature selection is not necessary.

Hybrid Approaches

- **Elastic Net**: Combines the L1 and L2 penalties, offering a balance between feature selection and shrinkage.
- **Adaptive LASSO**: Adapts the regularization parameter for each feature based on their initial estimates.

Polynomial Regression

Hồi quy đa thức (Polynomial Regression) là một dạng của phân tích hồi quy, trong đó mối quan hệ giữa các biến độc lập và biến phụ thuộc được mô hình hóa bằng đa thức bậc *n*.

Đối với **nhiều biến độc lập (Multiple Variable)**, các phép tính được thực hiện dưới dạng **ma trận** để thuận tiện cho việc tính toán và tối ưu.

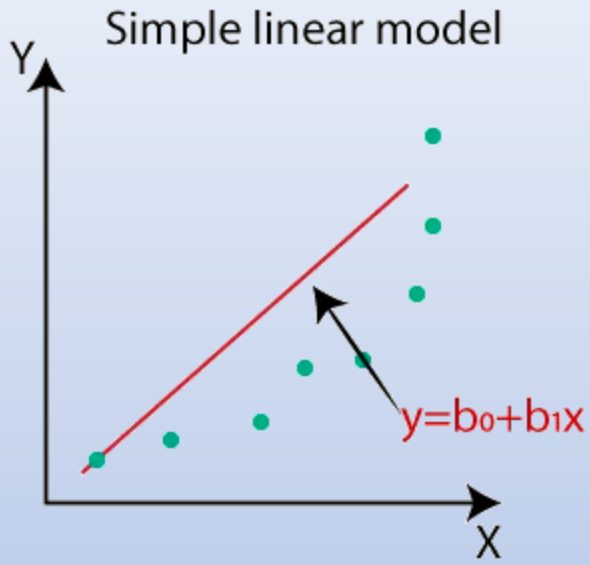
$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_1 & x_1^2 & \dots & x_1^m \\ 1 & x_2 & x_2^2 & \dots & x_2^m \\ 1 & x_3 & x_3^2 & \dots & x_3^m \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^m \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_m \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \\ \vdots \\ \varepsilon_n \end{bmatrix},$$

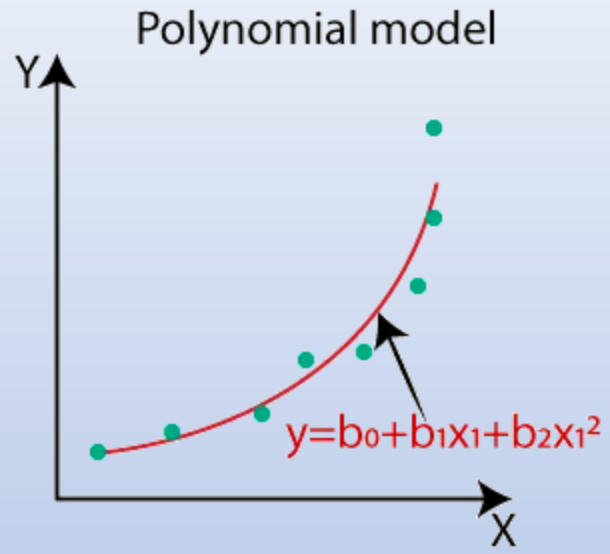
Hàm chi phí (Cost Function) trong hồi quy đa thức

- Hàm chi phí đo lường **hiệu suất của mô hình** bằng cách tính **sai số trung bình** giữa giá trị dự đoán và giá trị thực tế (hàm mất mát – *loss function* – là sai số của từng điểm dữ liệu riêng lẻ).
- Có thể hiểu:
  - **Loss function** là *điểm số của từng bài kiểm tra nhỏ*,
  - **Cost function** là *điểm trung bình tổng thể* của mô hình

$$J = \frac{1}{n}\sum_{i=1}^{n}(pred_i - y_i)^2$$

Hồi quy đa thức giúp **cải thiện độ khớp của mô hình** bằng cách tạo ra **đường cong** phù hợp hơn với dữ liệu, từ đó **giảm giá trị của hàm chi phí**. Các đa thức bậc cao hơn có thể đạt được độ khớp chính xác hơn — tuy nhiên cũng dễ dẫn đến hiện tượng *overfitting* nếu không kiểm soát tốt.

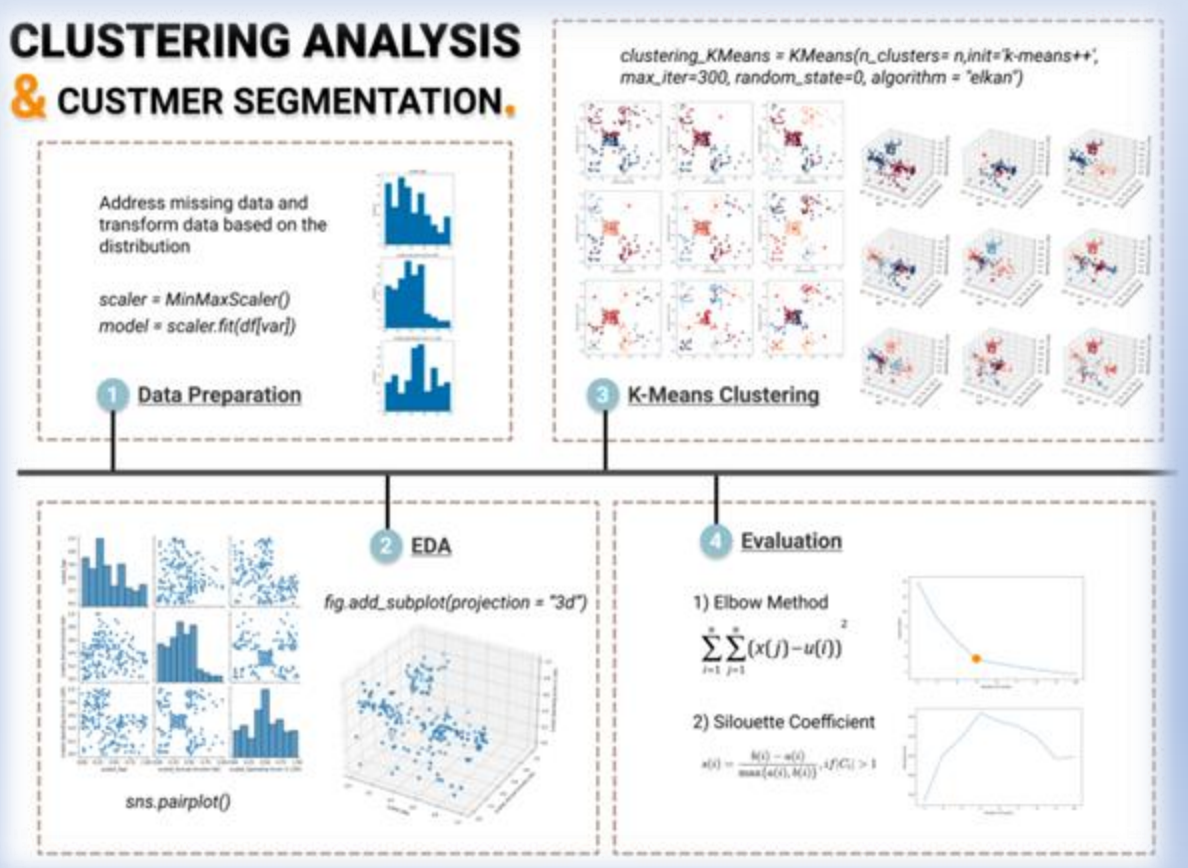


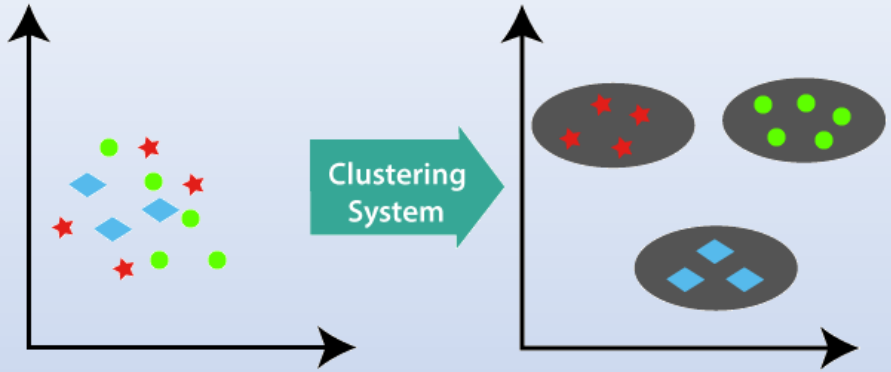


Simple Linear Regression	$y = b_0 + b_1 x_1$
Multiple Linear Regression	$y = b_0 + b_1 x_1 + b_2 x_2 + \ldots + b_n x_n$
Polynomial Linear Regression	$y = b_0 + b_1 x_1 + b_2 x_1^2 + \ldots + b_n x_1^n$

Phân cụm (Clustering)

Phân cụm (Clustering) là một kỹ thuật trong học máy (machine learning) được sử dụng để nhóm các điểm dữ liệu tương tự nhau thành từng cụm (nhóm). Thuật toán tự động phát hiện các mẫu (patterns) hoặc cấu trúc tự nhiên trong dữ liệu mà không cần có nhãn trước. Nói cách khác, phân cụm giúp chia dữ liệu thành các nhóm sao cho các điểm trong cùng một nhóm có đặc điểm giống nhau, còn các nhóm khác nhau thì có sự khác biệt rõ rệt.



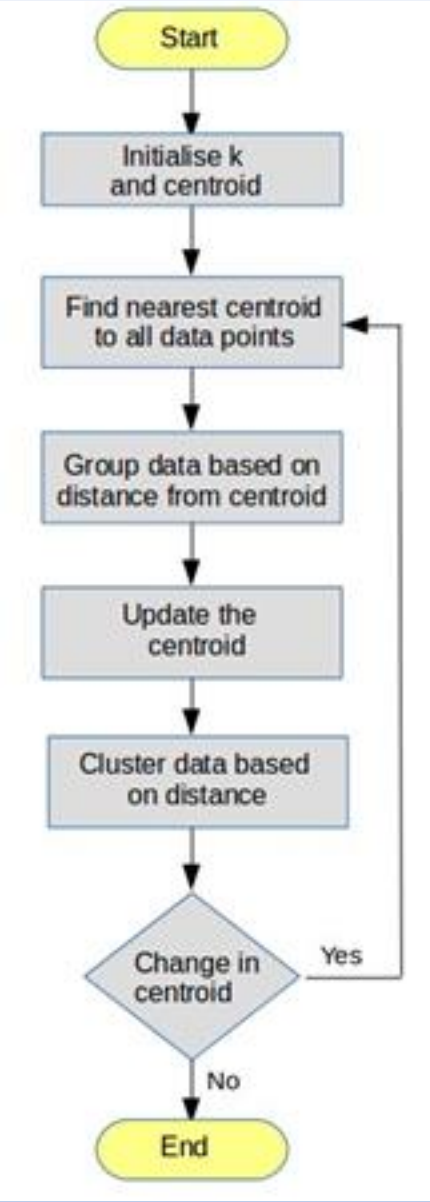


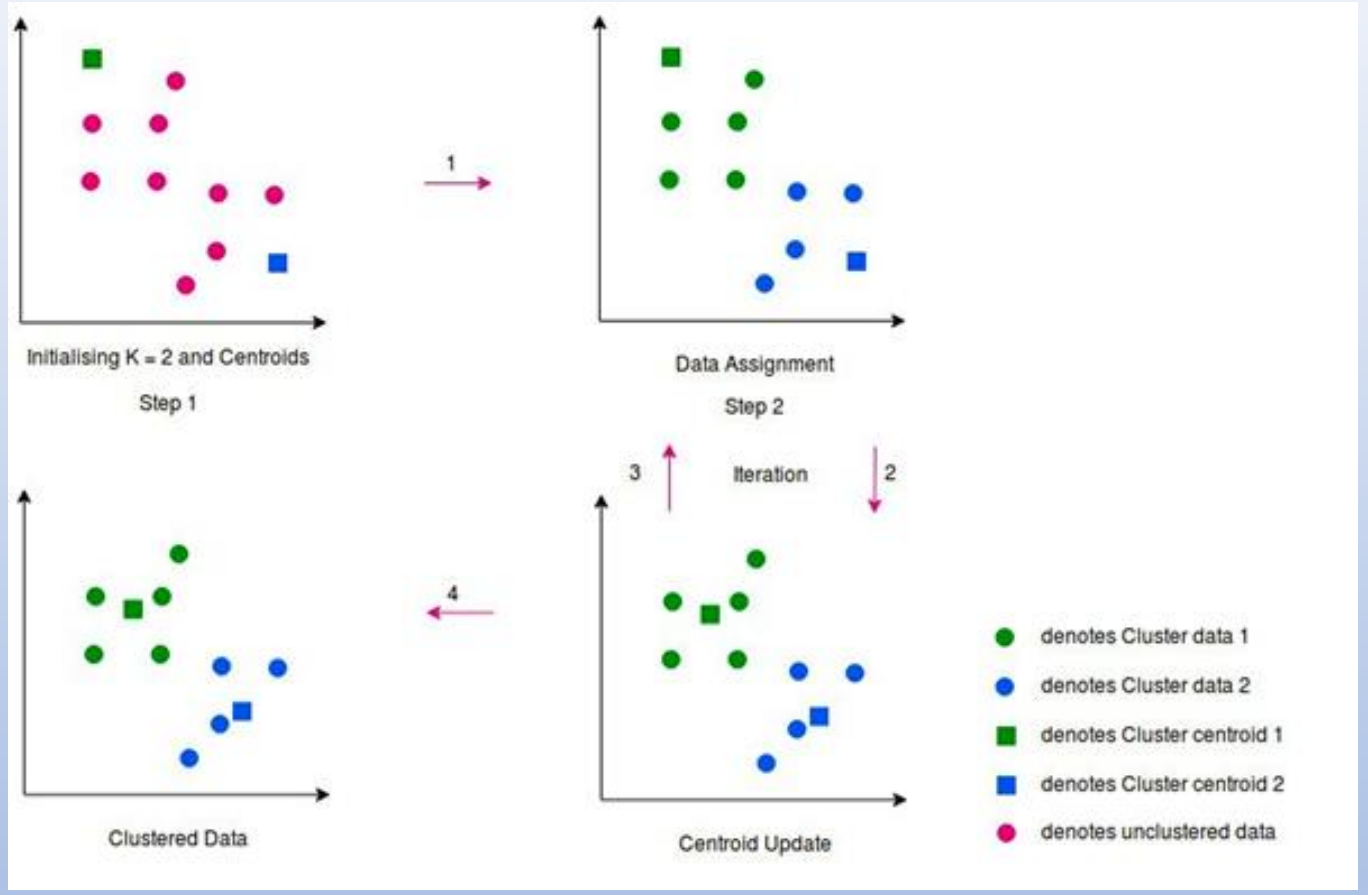
Ứng dụng của Phân cụm (Clustering Applications)

- Phân khúc khách hàng (Customer Segmentation): Nhóm các khách hàng lại với nhau dựa trên đặc điểm nhân khẩu học, hành vi mua hàng hoặc sở thích tiêu dùng.
- Phân đoạn ảnh (Image Segmentation): Chia một hình ảnh thành các vùng riêng biệt dựa trên màu sắc, kết cấu (texture) hoặc hình dạng.
- Phát hiện bất thường (Anomaly Detection): Xác định các điểm dữ liệu bất thường có sự khác biệt lớn so với phần còn lại của tập dữ liệu.
- Phân tích mạng xã hội (Social Network Analysis): Tìm ra các cộng đồng hoặc nhóm người dùng có mối liên hệ chặt chẽ trong mạng lưới.
- Tin sinh học (Bioinformatics): Phân tích mẫu biểu hiện gen hoặc cấu trúc protein để hiểu rõ hơn về các quá trình sinh học.

https://scikit-learn.org/stable/modules/clustering.html

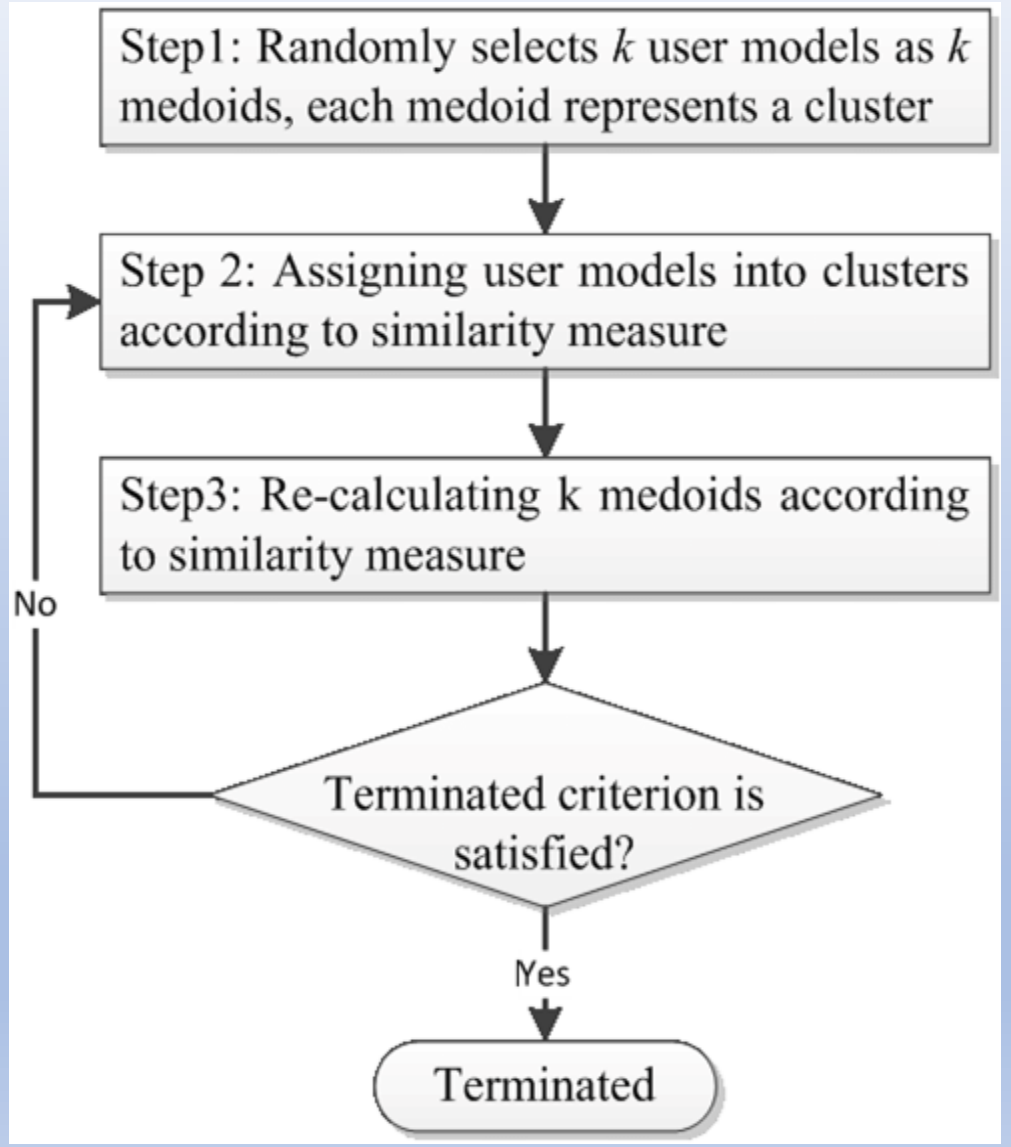
K-means Algorithm





1. Initialize k points, called the ‘centroid’, randomly or from the data set.
2. Data Assignment Step – Group all data points individually with its nearest centroid to form the clusters.
3. Centroid Update Step – Calculate the value of centroid that is the average of items belonging to each cluster.
4. Reiterate step 2 and 3, till the centroid value remains constant between consecutive iterations.

K-medoids Algorithm



Initialization:

- Randomly select k data points as medoids.

Assignment:

- Assign each data point to the nearest medoid based on a distance metric (e.g., Euclidean distance).

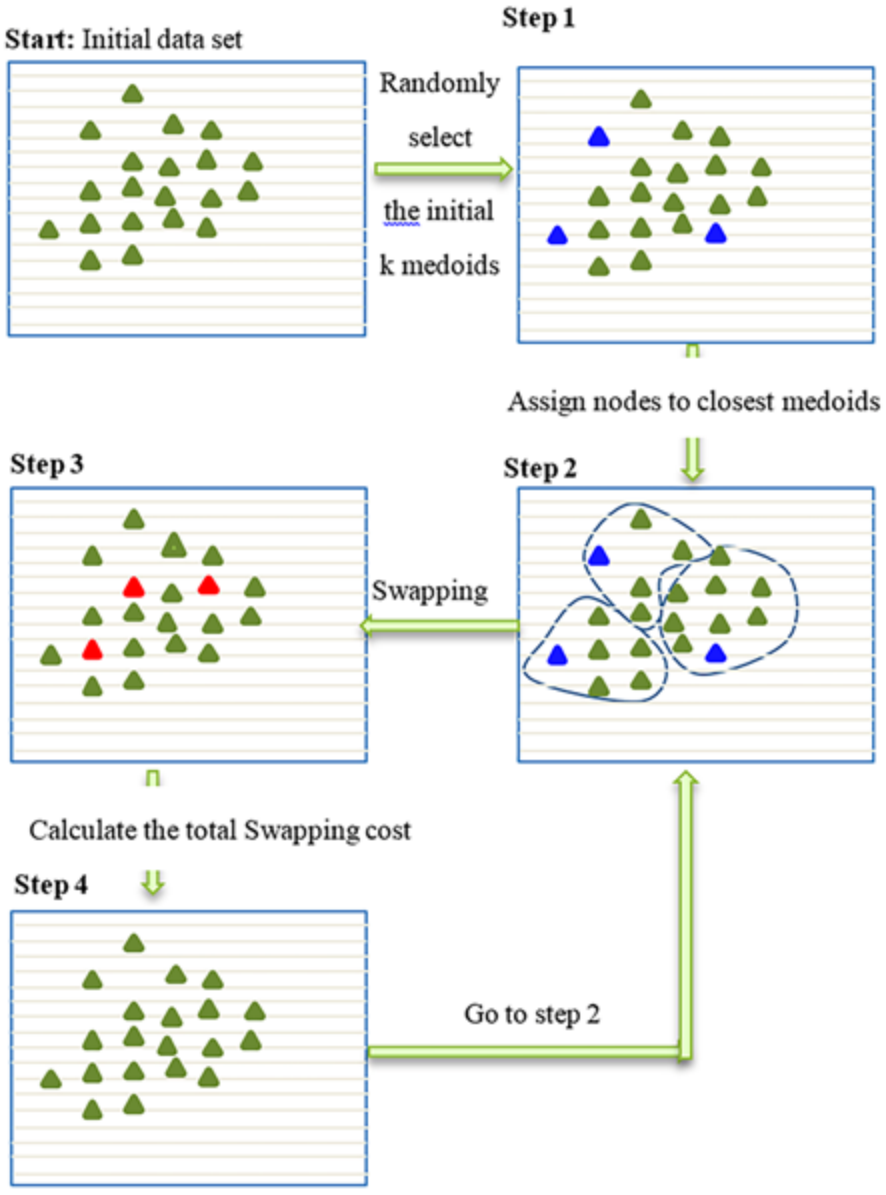
Update:

- For each medoid, calculate the sum of distances to all points assigned to it.
- Swap the current medoid with a non-medoid point if the swap results in a decrease in the overall sum of distances.
- Repeat this process for all medoids.

Repeat:

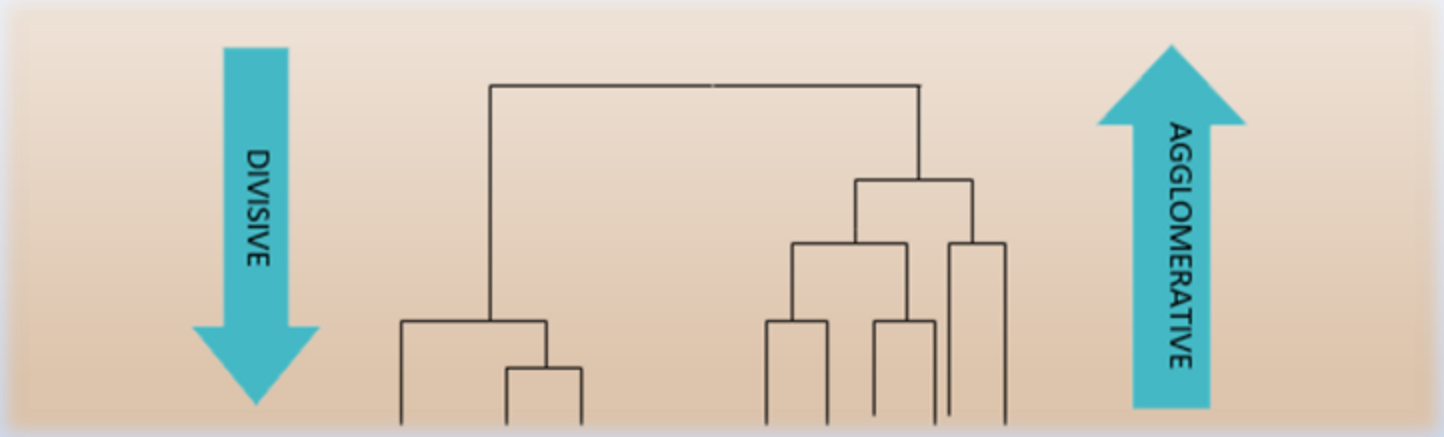
- Repeat steps 2 and 3 until there are no more changes in the medoid assignments or a specified number of iterations is reached.

K-medoids Algorithm



Example in Scikit-learn:
→ https://codinginfinite.com/k-medoids-clustering-algorithm-with-numerical-example/#google_vignette

Hierarchical Clustering Methods

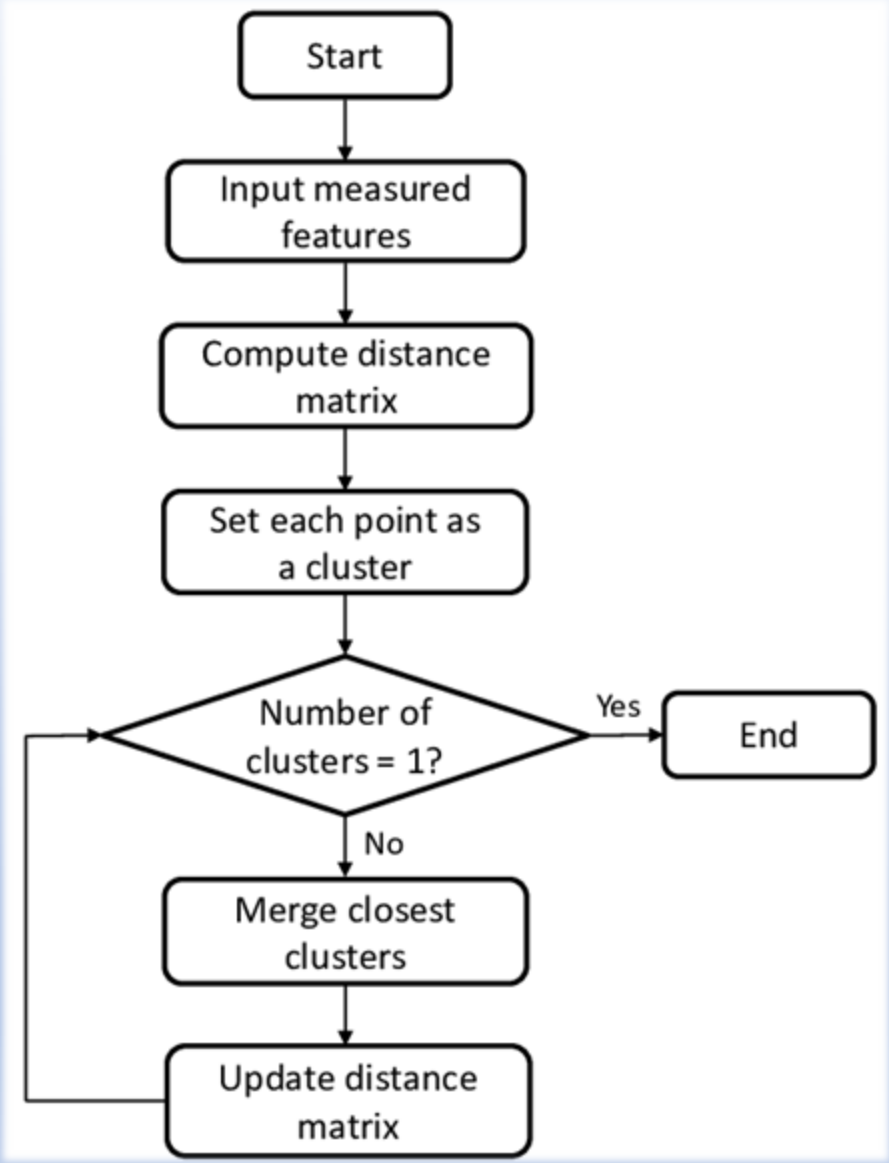


Phân cụm phân cấp (Hierarchical Clustering) sử dụng thước đo khoảng cách hoặc độ tương đồng để tạo thành các cụm mới. Kết quả của quá trình này thường được biểu diễn dưới dạng cây phân cấp (dendrogram), giúp ta quan sát cấu trúc phân cụm ở nhiều mức độ khác nhau.
Phân cụm phân cấp được chia thành hai loại chính, dựa trên cách hình thành cụm trong quá trình phân tích:

- Phân cụm kết hợp (Agglomerative Hierarchical Clustering – AHC),
- Phân cụm phân chia (Divisive Hierarchical Clustering – DHC)

Việc lựa chọn phương pháp phân cụm phân cấp (Hierarchical Clustering) phụ thuộc vào nhiều yếu tố khác nhau, bao gồm:
1. Kích thước tập dữ liệu (Dataset size): Với tập dữ liệu lớn, phương pháp phân chia (Divisive) thường hiệu quả hơn vì giảm được số lần tính toán khoảng cách khi so sánh từng cặp điểm.
2. Mức độ nhiễu (Noise level):Với dữ liệu có nhiễu cao, phương pháp phân chia (Divisive) thường ổn định và chính xác hơn, tránh việc gộp sai các điểm nhiễu vào cụm.
3. Hình dạng cụm (Cluster shape): Cả hai phương pháp (Agglomerative và Divisive) đều có thể xử lý các cụm có hình dạng bất kỳ, tuy nhiên tiêu chí gộp hoặc tách cụm (linkage/splitting criteria) sẽ ảnh hưởng trực tiếp đến kết quả cuối cùng.
4. Số lượng cụm mong muốn (Desired number of clusters):Phương pháp kết hợp (Agglomerative) linh hoạt hơn trong việc xác định số lượng cụm, vì ta có thể "cắt" cây dendrogram ở nhiều mức độ khác nhau để thu được các cụm mong muốn.

Hierarchical Clustering Methods



Quy trình của **phân cụm kết hợp (Agglomerative Clustering)** có thể được tóm tắt như sau:

Bước 1: Tính ma trận khoảng cách (proximity matrix) bằng một hàm đo khoảng cách cụ thể (ví dụ: Euclidean, Manhattan,…).

Bước 2: Mỗi điểm dữ liệu ban đầu được xem là một cụm riêng biệt.

Bước 3: Gộp hai cụm gần nhau nhất dựa trên thước đo độ tương đồng giữa các cụm (như single linkage, complete linkage, average linkage,…).

Bước 4: Cập nhật lại ma trận khoảng cách, phản ánh khoảng cách mới giữa các cụm sau khi gộp.

Bước 5: Lặp lại Bước 3 và Bước 4 cho đến khi chỉ còn một cụm duy nhất bao gồm toàn bộ dữ liệu.

https://scikit-learn.org/stable/auto_examples/cluster/plot_agglomerative_dendrogram.html

TÀI LIỆU THAM KHẢO

1. Han, Kamber & Pei – *Data Mining: Concepts and Techniques*.
2. Géron, Aurélien – *Hands-on Machine Learning with Scikit-Learn, Keras & TensorFlow*.
3. IBM – *CRISP-DM Process Model*.
4. scikit-learn.org – *Model Selection and Evaluation Guide*.
5. Kaggle datasets cho thực hành mô hình hóa.