Chương 6.

Evaluation model – Đánh giá mô hình



PhD. Nguyễn Thị Khánh Tiên
tiennkt@ut.edu.vn

Mục tiêu:

- Đánh giá hiệu quả mô hình theo mục tiêu nghiệp vụ.

Sau khi học xong chương này, sinh viên có thể:

- Hiểu ý nghĩa của giai đoạn đánh giá trong CRISP-DM.
- Sử dụng các **chỉ số đánh giá** phù hợp cho từng loại bài toán (phân loại, hồi quy, phân cụm).
- So sánh và chọn mô hình tối ưu.
- Liên kết kết quả mô hình với **mục tiêu nghiệp vụ** đã đặt ra ở giai đoạn đầu.

Nội dung chính:

- Các chỉ số đánh giá: Accuracy, Precision, Recall, F1, ROC-AUC, RMSE.
- Phân tích ma trận nhầm lẫn, đường ROC.
- Đánh giá mô hình theo tiêu chí kinh doanh (lợi nhuận, rủi ro).
- So sánh nhiều mô hình, chọn mô hình tối ưu.
- Thực hành: chọn mô hình tốt nhất cho bộ dữ liệu thực tế.

Vai trò của đánh giá mô hình:

- Xác định mức độ chính xác của mô hình.
- Kiểm tra khả năng khái quát hoá (generalization) trên dữ liệu mới.
- Đảm bảo mô hình **phù hợp với mục tiêu nghiệp vụ**, không chỉ tốt về mặt kỹ thuật.
- Nếu mô hình không đạt yêu cầu → quay lại bước **Data Preparation** hoặc **Modeling** để cải tiến.

Các phương pháp đánh giá:

❖**Đánh giá chéo (Cross-validation)**

- Chia dữ liệu thành **k phần (fold)**.
- Huấn luyện mô hình trên (k-1) phần, kiểm thử trên phần còn lại.
- Lặp lại k lần → lấy trung bình kết quả.
- Giảm rủi ro do chia dữ liệu ngẫu nhiên.
- Sử dụng cross_val_score trong scikit-learn.

❖**Đánh giá trên tập Train/Test Split**

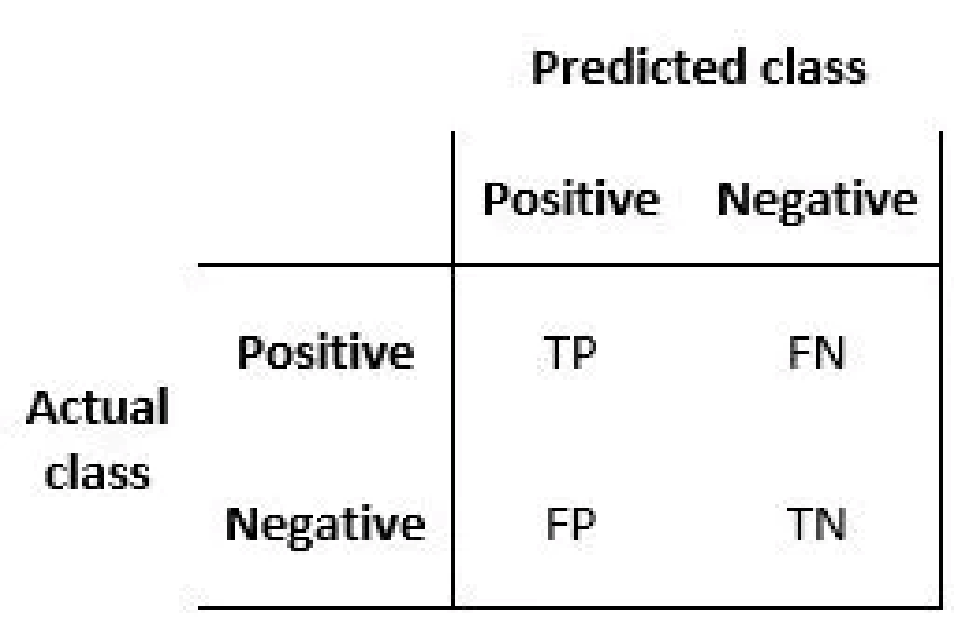
- Chia dữ liệu thành:

  Train set: 70–80% dữ liệu để huấn luyện.

  Test set: 20–30% để kiểm thử.

Các chỉ số đánh giá cho bài toán Phân loại (Classification)

Chỉ số	Ý nghĩa	Ghi chú
Accuracy	Tỷ lệ dự đoán đúng	Không phù hợp khi dữ liệu mất cân bằng
Precision	Tỷ lệ dự đoán đúng trong các mẫu dự đoán dương	Quan trọng khi chi phí false positive cao
Recall	Tỷ lệ phát hiện đúng các mẫu dương thật	Quan trọng khi cần phát hiện hết trường hợp thật
F1-score	Trung bình điều hòa giữa Precision và Recall	Dùng khi cần cân bằng
ROC-AUC	Diện tích dưới đường cong ROC	Đánh giá khả năng phân biệt hai lớp



Ma trận nhầm lẫn (Confusion Matrix)

Ma trận nhầm lẫn là một bảng mô tả sự kết hợp giữa **giá trị dự đoán** và **giá trị thực tế**. Gồm các thành phần:

- **True Positive (TP)**: Mô hình dự đoán *dương* và thực tế cũng *dương*.
- **True Negative (TN)**: Mô hình dự đoán *âm* và thực tế cũng *âm*.
- **False Positive (FP)**: Mô hình dự đoán *dương* nhưng thực tế *âm*.
- **False Negative (FN)**: Mô hình dự đoán *âm* nhưng thực tế *dương*.

Precision (Độ chính xác cho lớp dương)

Precision cho biết trong tất cả các mẫu mà mô hình dự đoán là *dương*, thì có bao nhiêu mẫu thật sự là *dương*.

$$Precision = \frac{TP}{TP + FP}$$

Recall (Độ bao phủ)

Recall cho biết trong tất cả các mẫu *dương* thực sự tồn tại, mô hình đã dự đoán đúng được bao nhiêu mẫu.

$$Recall = \frac{TP}{TP + FN}$$

F1-Score

F1-score là **trung bình điều hoà (harmonic mean)** giữa Precision và Recall.

F1-score được dùng để cân bằng giữa Miss (FN) và False Alarm (FP).

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

F1 là lựa chọn hiệu quả trong các trường hợp:

Khi **FP và FN quan trọng như nhau**.

Khi **bổ sung thêm dữ liệu không cải thiện nhiều kết quả dự đoán**.

Khi **TN rất lớn**, dẫn đến Accuracy trở nên "ảo tưởng" (vì mô hình đoán âm nhiều là đã cao)

ROC (Receiver Operating Characteristic) là một đồ thị giúp biểu diễn nhiều **ma trận nhầm lẫn** tại **các ngưỡng (threshold)** khác nhau một cách trực quan và elegant. Thay vì chỉ nhìn một confusion matrix tại một ngưỡng 0.5, ROC xem xét toàn bộ các ngưỡng từ 0 → 1.

Mỗi điểm trên đường ROC tương ứng với một ngưỡng dự đoán.

- Ngưỡng thấp → dự đoán nhiều mẫu là dương → TPR cao nhưng FPR cũng cao
- Ngưỡng cao → dự đoán ít mẫu dương → TPR thấp nhưng FPR thấp

AUC (Area Under the Curve). AUC là **diện tích dưới đường cong ROC**. AUC càng lớn → mô hình càng có khả năng phân biệt tốt giữa hai lớp.

1. TPR (True Positive Rate)

Còn gọi là: **Recall**, **Sensitivity**

$$TPR = \frac{TP}{TP + FN}$$

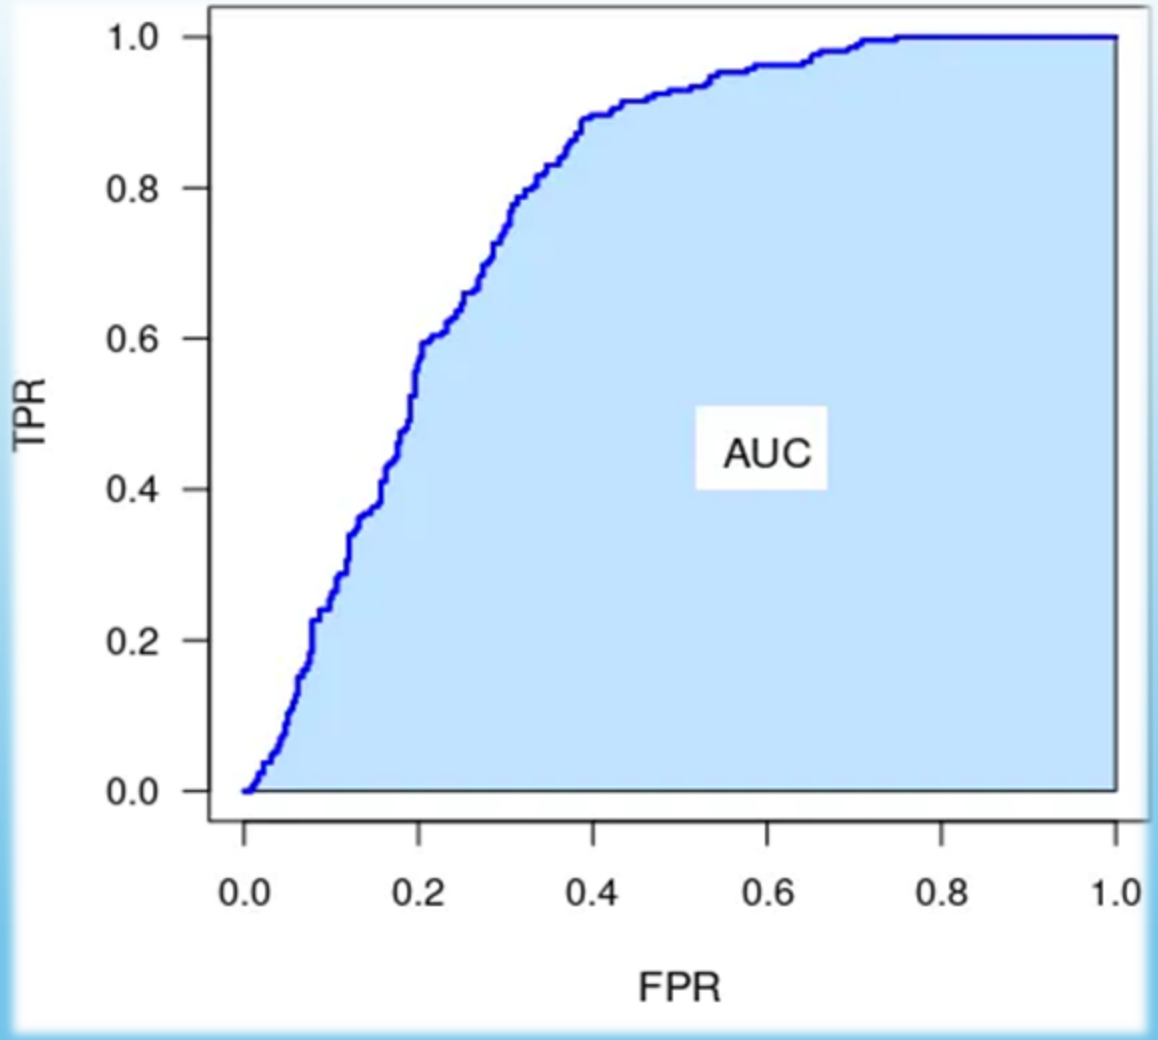
TPR cho biết mô hình bắt được bao nhiêu mẫu *dương* thật sự.

2. FPR (False Positive Rate)

Còn gọi là: **1 – Specificity**

$$FPR = \frac{FP}{FP + TN}$$

FPR cho biết mô hình nhầm lẫn bao nhiêu mẫu *âm* thành *dương*.



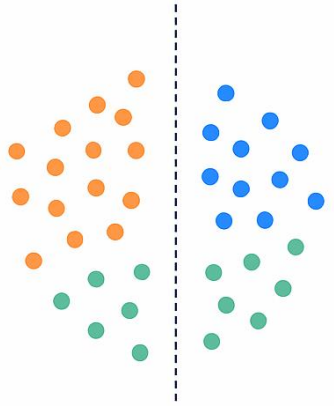
Các chỉ số đánh giá cho bài toán Regression

Mean Squared Error (MSE)	**$MSE = 1/n * \Sigma(y_i - \hat{y}_i)^2$**	Đo **độ lệch bình phương trung bình** giữa giá trị thực tế và giá trị dự đoán. Giá trị **MSE càng nhỏ → mô hình càng tốt**. Nhạy với outlier vì sai số được bình phương.
Root Mean Squared Error (RMSE)	**$RMSE = \sqrt{(MSE)}$**	Là **căn bậc hai của MSE**. Thường được ưu tiên dùng vì **có cùng đơn vị đo với biến mục tiêu**. Vẫn nhạy với outlier
Mean Absolute Error (MAE)	**$MAE = 1/n * \Sigma\lvert y_i - \hat{y}_i\rvert$**	Đo **độ lệch tuyệt đối trung bình** giữa giá trị dự đoán và giá trị thực tế. **Ít nhạy với outlier** hơn MSE và RMSE.
R-squared (R^2)	**$R^2 = 1 - SSres / SStot$**	Đo **tỉ lệ phương sai của biến phụ thuộc được giải thích bởi các biến độc lập**. **R^2 cao → mô hình giải thích dữ liệu tốt hơn**.
Adjusted R-squared	**Adjusted R^2 $= 1 - (1 - R^2) * (n - 1) / (n - p - 1)$**	Dùng để **phạt các biến giải thích không cần thiết**. Nếu thêm biến mới không hữu ích → Adjusted R^2 **giảm**. Phù hợp để so sánh mô hình có số lượng biến khác nhau.
Mean Absolute Percentage Error (MAPE)	**MAPE $= 100 * 1/n * \Sigma\lvert y_i - \hat{y}_i\rvert / \lvert y_i\rvert$**	Đo **sai số trung bình theo phần trăm** giữa giá trị dự đoán và thực tế. Hữu ích khi **so sánh mô hình trên các thang đo khác nhau**. Nhạy với các giá trị **$y = 0$**.
Weighted Mean Squared Error (WMSE)	**$WMSE = 1/n * \Sigma w_i * (y_i - \hat{y}_i)^2$**	Là **MSE có trọng số**, trong đó mỗi điểm dữ liệu có mức độ quan trọng khác nhau. Dùng khi một số mẫu nên được ưu tiên hơn (ví dụ: lỗi ở vùng giá trị lớn hoặc khách hàng quan trọng).

Chỉ số đánh giá cho bài toán Clustering

Chỉ số	Ý nghĩa
Silhouette Score	Đo **độ tách biệt và độ gọn** của các cụm. Giá trị càng gần **1** → cụm càng rõ ràng, tách biệt tốt.
Davies–Bouldin Index (DBI)	Đo mức độ **giống nhau giữa các cụm**. **DBI càng nhỏ → cụm càng tốt**, phân tách rõ hơn.
Calinski–Harabasz Score (CH Score)	Đo mức độ **tách biệt giữa các cụm so với độ gọn trong cụm**. **CH càng lớn → chất lượng phân cụm càng cao**.

Độ tách biệt giữa các cụm



Silhouette Score

$$s = \frac{b - a}{max(a,)}$$

- Khoảng cách trung binh đến các điểm cùng cụm
- Khoảng cách trung binh đến các điểm trong cụm gần nhất khác

Davies-Bouldin Index

Mức độ phân tách giữa các cụm

$$DBI = \frac{1}{k} \sum_{j \neq i} \frac{s_l + s_l}{d_{ij}}$$

- DBI càng nhỏ → cụm càng tốt

Calinski-Harabasz Score

Tách biệt / Gọn gàng

$$CH = \frac{\text{Between-cluster variance}}{\text{Within-cluster variance}}$$

- CH càng lớn → cụm càng tách biệt và gọn gàng

Bài tập thực hành

1) Tính **Accuracy, Precision, Recall, F1** cho mô hình Decision Tree và Logistic Regression trên cùng tập dữ liệu Titanic.
2) Dùng **Cross-validation (k=5)** để đánh giá mô hình Random Forest.
3) Đối với bài toán hồi quy (House Prices), tính **MAE, RMSE, R^2** và so sánh hai mô hình Linear vs. Random Forest Regressor.
4) Giải thích vì sao mô hình tốt về kỹ thuật nhưng chưa chắc tốt về mặt nghiệp vụ.



TÀI LIỆU THAM KHẢO

1. Han, Kamber & Pei – *Data Mining: Concepts and Techniques*.
2. Géron, Aurélien – *Hands-on Machine Learning with Scikit-Learn, Keras & TensorFlow*.
3. IBM – *CRISP-DM Process Model*.
4. scikit-learn.org – *Model Selection and Evaluation Guide*.
5. Kaggle datasets cho thực hành mô hình hóa.