Giới thiệu và khám phá dữ liệu (Exploratory Data Analysis)

A. Mục tiêu: Làm quen dữ liệu bảng và các thao tác cơ bản. Cụ thể:

- Hiểu cấu trúc dữ liệu dạng bảng và các bước đầu trong quy trình **CRISP-DM**.
- Sử dụng Python (pandas, matplotlib, seaborn) để:
  - Nạp dữ liệu, xem kích thước, kiểu dữ liệu, và thống kê mô tả.
  - Kiểm tra và xử lý **giá trị thiếu (missing values)**, **ngoại lệ (outliers)**.
  - Thực hiện **mã hóa (encoding)** và **chuẩn hóa dữ liệu (normalization)**.
- Trực quan hóa dữ liệu bằng biểu đồ cơ bản.

B. Công cụ và tài nguyên

- Ngôn ngữ: Python
- Thư viện: pandas, numpy, matplotlib, seaborn, scikit-learn
- Môi trường: Google Colab hoặc Jupyter Notebook (VSCode)
- Dataset mẫu: Titanic, Iris, Heart Disease, Student Performance
- Nguồn tham khảo:
  - https://www.geeksforgeeks.org/data-analysis/eda-with-NumPy-Pandas-Matplotlib-Seaborn/
  - https://seaborn.pydata.org/tutorial.html
  - https://scikit-learn.org/stable/modules/preprocessing.html

C. Bài tập:

Bài 1 – Khám phá dữ liệu Titanic

Dataset: Titanic Dataset (Kaggle)

Yêu cầu:

1. Nạp dữ liệu và hiển thị 5 dòng đầu tiên.
2. Xác định có bao nhiêu dòng, bao nhiêu cột.
3. Thống kê các cột dạng số (describe()), đếm giá trị thiếu.
4. Vẽ histogram cho thuộc tính *Age* và boxplot cho *Fare*.
5. Điền giá trị trung vị cho *Age* bị thiếu.
6. Chuẩn hóa các cột *Age* và *Fare*.
7. Mã hóa cột *Sex* và *Embarked* thành dạng số.
8. Lưu tập dữ liệu sau xử lý thành titanic_clean.csv.

Bài 2 – Dữ liệu Iris

Dataset: Iris.csv (có sẵn trong thư viện sklearn)

Yêu cầu:

1. Hiển thị thông tin các đặc trưng và nhãn.
2. Tính trung bình, độ lệch chuẩn của từng đặc trưng.
3. Vẽ biểu đồ cặp (sns.pairplot) để thấy mối tương quan giữa các đặc trưng.
4. Chuẩn hóa dữ liệu về thang [0,1] bằng MinMaxScaler.
5. Giải thích ý nghĩa của chuẩn hóa trong học máy.

Bài 3 – Viết báo cáo cho bài 1 và bài 2 theo nhóm.